

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-100863-122823

**Detekcia poruchových stavov na
zariadeniach v prevádzke pomocou metód
strojového učenia**

Bakalárska práca

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-100863-122823

**Detekcia poruchových stavov na
zariadeniach v prevádzke pomocou metód
strojového učenia**

Bakalárska práca

Študijný program: robotika a kybernetika

Študijný odbor: kybernetika

Školiace pracovisko: Ústav robotiky a kybernetiky

Vedúci záverečnej práce: Ing. Slavomír Kajan, PhD.

Bratislava 2026

levgeniia levgrafova



ZADANIE BAKALÁRSKEJ PRÁCE

Študentka: **Ievgeniia Ievgrafova**
ID študenta: 122823
Študijný program: robotika a kybernetika
Študijný odbor: kybernetika
Vedúci práce: Ing. Slavomír Kajan, PhD.
Vedúci pracoviska: prof. Ing. František Duchoň, PhD.
Miesto vypracovania: Ústav robotiky a kybernetiky

Názov práce: **Detekcia poruchových stavov na zariadeniach v prevádzke pomocou metód strojového učenia**

Jazyk, v ktorom sa práca vypracuje: slovenský jazyk

Špecifikácia zadania:

Cieľom bakalárskej práce je vytvoriť demonštračné ukážky na detekciu poruchových stavov (anomálií) na zariadeniach v prevádzke pomocou metód strojového učenia, ktoré nevyžadujú veľké množstvo dát z poruchových stavov.

Úlohy:

1. Naštudujte metódy strojového učenia vhodné na detekciu anomálií z meraných dát zariadenia v prevádzke.
2. Vyberte vhodné datasety na detekciu anomálií.
3. Realizujte viaceré metódy strojového učenia na detekciu anomálií na vybraných datasetoch.
4. Porovnajte kvalitu jednotlivých metód strojového učenia.
5. Vyhodnoťte dosiahnuté výsledky.

Termín odovzdania bakalárskej práce: 05. 06. 2026
Dátum schválenia zadania bakalárskej práce: 13. 10. 2025
Zadanie bakalárskej práce schválil: doc. Ing. Eva Miklovičová, PhD. – garantka študijného programu

Pod'akovanie

Rada by som sa poďakovala svojmu vedúcemu bakalárskej práce Ing. Slavomírovi Kajanovi, PhD. za jeho odborné vedenie, cenné pripomienky a čas, ktorý mi venoval počas vypracovania tejto práce. Zároveň ďakujem svojej rodine a priateľom za ich neustálu podporu.

Abstrakt

Táto bakalárska práca sa zaoberá detekciou poruchových stavov a anomálií v technických systémoch pomocou metód strojového učenia. Hlavným cieľom práce je analyzovať možnosti detekcie anomálií v situáciách, keď je k dispozícii len obmedzené množstvo poruchových dát, čo predstavuje častý problém v priemyselnej diagnostike.

V teoretickej časti sú predstavené základné typy anomálií, prístupy strojového učenia a vybrané algoritmy vhodné pre detekciu anomálií. Podrobnejšie sú opísané metódy Isolation Forest, One-Class SVM a Autoencoder, ktoré boli následne použité v experimentálnej časti práce.

Praktická časť sa venuje predspracovaniu a analýze datasetov NAB, ECG5000 a NASA Battery. Na týchto datasetoch boli implementované a porovnané vybrané metódy v programovacom jazyku Python. Modely boli trénované prevažne na normálnych dátach a ich výkonnosť bola hodnotená pomocou metrík Accuracy, Precision, Recall a F1-score. Súčasťou experimentov bolo aj skúmanie vplyvu rozhodovacích prahov a rôznych pomerov trénovacích dát na úspešnosť detekcie.

Dosiahnuté výsledky ukázali, že všetky skúmané metódy sú schopné identifikovať anomálie aj pri nedostatku poruchových vzoriek, pričom ich úspešnosť závisí od charakteru dát a vhodného nastavenia parametrov. Práca zároveň poskytuje metodiku, ktorá môže byť využitá pri návrhu systémov prediktívnej údržby a diagnostiky technických zariadení.

Kľúčové slová

Detekcia anomálií, strojové učenie, priemyselná diagnostika, poruchové stavy, Isolation Forest, One-Class SVM, Autoencoder

Abstract

This bachelor thesis focuses on the detection of fault conditions and anomalies in technical systems using machine learning methods. The main objective of the thesis is to investigate anomaly detection approaches in situations where only a limited amount of faulty data is available, which is a common challenge in industrial diagnostics.

The theoretical part introduces the basic types of anomalies, machine learning approaches, and selected algorithms suitable for anomaly detection. Particular attention is devoted to the Isolation Forest, One-Class SVM, and Autoencoder methods, which were subsequently applied in the experimental part of the thesis.

The practical part focuses on the preprocessing and analysis of the NAB, ECG5000, and NASA Battery datasets. The selected methods were implemented and evaluated in the Python programming language. The models were trained primarily on normal operating data, and their performance was assessed using Accuracy, Precision, Recall, and F1-score metrics. The experiments also examined the influence of decision thresholds and different training data proportions on anomaly detection performance.

The obtained results demonstrate that all evaluated methods are capable of detecting anomalies even when fault samples are scarce. Their effectiveness depends on the characteristics of the analyzed data and the proper selection of model parameters. The thesis also provides a methodology that can be applied in predictive maintenance and technical diagnostics systems.

Keywords

Anomaly detection, machine learning, industrial diagnostics, fault conditions, Isolation Forest, One-Class SVM, Autoencoder

Obsah

Zoznam obrázkov	9
Zoznam tabuliek	13
Zoznam značiek a skratiek	14
Úvod	15
1 Teoretické východiská	16
1.1 Základy detekcie porúch a anomálií	16
1.1.1 Klasické klasifikácie porúch (pri dostatku dát)	16
1.2 Typy anomálií a poruchových stavov v technických systémoch	19
1.3 Úloha umelej inteligencie a strojového učenia v priemyselnej diagnostike	20
1.4 Metódy strojového učenia pre detekciu anomálií	22
1.4.1 Supervised, unsupervised a semi-supervised prístupy	22
1.4.2 Prehľad metód detekcie anomálií (LOF, K-Means, PCA, DBSCAN, GMM)	23
1.5 Vybrané metódy na porovnanie	27
1.5.1 Isolation Forest	27
1.5.2 One-Class SVM	29
1.5.3 Autoencoder	29
2 Analýza a výber dátových súborov	30
2.1 Kritériá výberu datasetov	31
2.2 Použité datasety	32
2.2.1 Numenta Anomaly Benchmark (NAB) – Industrial Temperature Time Series	32
2.2.2 ECG5000 Dataset	34
2.2.3 NASA Battery Health Dataset	37
2.3 Iné známe datasety pre detekciu anomálií (stručný prehľad)	40
2.3.1 Transakcie Kreditných Kariet (Credit Card Transactions – Fraud Detection)	41
2.3.2 KDD Cup 1999 (detekcia narušení v sieťovej komunikácii)	41
2.3.3 Dataset Raketoplánu (Shuttle Dataset)	41
2.3.4 Dataset Arytmií (Arrhythmia Dataset)	41
2.3.5 Typ Pôdneho Pokryvu (Forest Cover Type Dataset)	41
2.3.6 Bezpečný Vodárenský Systém (SWaT – Secure Water Treatment)	42
2.3.7 Telemetrické Dáta z Vesmírnych Misií (SMAP & MSL)	42
3 Návrh a implementácia riešenia	42
3.1 Architektúra systému detekcie anomálií	43
3.2 Predspracovanie dát, extrakcia príznakov a delenie datasetov	44

3.2.1 Predspracovanie priemyselného datasetu (NAB)	44
3.2.2 Predspracovanie datasetu ECG5000.....	46
3.2.3 Predspracovanie datasetu NASA Battery.....	47
3.3 Implementácia metód v jazyku Python	49
3.3.1 Implementácia metód Isolation Forest.....	50
3.3.2 Implementácia metód One-Class SVM.....	50
3.3.3 Implementácia metód Autoencoder.....	51
3.4 Porovnanie výpočtovej náročnosti metód	51
4 Experimentálne výsledky a porovnanie metód	52
4.1 Nastavenie experimentov	52
4.2 Metriky hodnotenia (Precision, Recall, atď.)	54
4.3 Výsledky pre jednotlivé metódy.....	54
4.3.1 Výsledky pre Isolation Forest.....	55
4.3.2 Výsledky pre One-Class SVM	64
4.3.3 Výsledky pre Autoencoder.....	71
4.4 Porovnanie výsledkov	80
4.5 Diskusia o vhodnosti metód pre priemyselné prostredie	81
5 Vyhodnotenie a zhodnotenie dosiahnutých výsledkov	83
5.1 Splnenie cieľov práce	83
5.2 Porovnanie s inými prístupmi	83
5.3 Možnosti budúceho rozšírenia a aplikácie v praxi.....	84
Záver	86
Literatúra	87
Prílohy	92
Príloha A – Programové súbory.....	92
Príloha B – Používateľská príručka	93
Príloha C – Inštalácia a konfigurácia	94
Použitie nástrojov umelej inteligencie	96

Zoznam obrázkov

Obrázok 1 – Rozhodovací strom [26].....	17
Obrázok 2 – Algoritmus SVM maximalizuje šírku marginu medzi dvoma triedami, znázornenými symbolmi + a -, ktoré sú oddelené separačnou hyperrovinou. [27].....	17
Obrázok 3 – Vizualizácia fungovania algoritmu KNN [28]	18
Obrázok 4 – Schéma metódy Random Forest [29]	18
Obrázok 5 – Schémy metód CNN, ANN, RNN [30]	18
Obrázok 6 - Vztah medzi AI,ML a DL (podľa Koubaa & Azar,2021,s. 12)[2]	20
Obrázok 7 – Diagram supervised a unsupervised učenia. [31]	22
Obrázok 8 – Demonštrácia výpočtu lokálnej hustoty a identifikácie odľahlých bodov v algoritme Local Outlier Factor [32]	24
Obrázok 9 – Ilustrácia fungovania algoritmu K-Means: rozdelenie dátových bodov do klastrov na základe ich podobnosti [33]	24
Obrázok 10 – Vizualizácia hlavných komponentov PCA: V1 zachytáva maximálnu variabilitu dát, zatiaľ čo V2 je na V1 kolmá a nesie menšiu časť variability [34]	25
Obrázok 11 – Porovnanie pôvodných dát a výsledku klastrovania pomocou algoritmu DBSCAN [35]	26
Obrázok 12 – Vizualizácia troch odlišných jednorozmerných Gaussových distribúcií [36]	27
Obrázok 13 – Schéma princípu izolácie anomálií v modeli iForest [9]	28
Obrázok 14 – Vizualizácia detekcie anomálií pomocou One-Class SVM [37]	29
Obrázok 15 – Všeobecná architektúra autoenkódera (AE) [38]	30
Obrázok 16 – Príklad detekcie anomálií na teplote pomocou autoenkódera. [39]	33
Obrázok 17 – Rozdelenie hodnôt teploty v časovom rade priemyselného zariadenia [39]	33

Obrázok 18 – Detekcia anomálií v časovom rade teploty pomocou metódy One-Class SVM [39]	34
Obrázok 19 – Normálny EKG signál [40]	35
Obrázok 20 – Anomálny EKG signál [40]	36
Obrázok 21 – Rekonštrukcia normálneho EKG signálu pomocou autoenkódera [40].	36
Obrázok 22 – Rekonštrukcia anomálneho EKG signálu pomocou autoenkódera [40]	37
Obrázok 23 – Trend elektrochemického odporu batérie počas degradácie [51]	39
Obrázok 24 – Priebeh vybíjacieho cyklu batérie (viacrozmerné merania) [50]	40
Obrázok 25 – Architektúra systému detekcie anomálií	44
Obrázok 26 – Ukážka extrahovaných príznakov z priemyselného časového radu	45
Obrázok 27 – Ukážka štandardizovaných EKG cyklov s binárnou anotáciou anomálie	46
Obrázok 28 – Ukážka multivariantných senzorových dát batérie počas vybíjania s doplnenou kapacitou a anotáciou cyklu	48
Obrázok 29 – Matica zámen metódy Isolation Forest pre dataset NASA Battery pri hodnote threshold_list = 0,065 a train_cycle_fraction = 0,90	57
Obrázok 30 – Histogram hodnôt rozhodovacej funkcie metódy Isolation Forest pre dataset NASA Battery pri hodnote threshold_list = 0,065, train_cycle_fraction = 0,90 a seed = 43	58
Obrázok 31 – Matica zámen metódy Isolation Forest pre dataset ECG5000 pri hodnote threshold_list = 0	60
Obrázok 32 – Histogram hodnôt rozhodovacej funkcie metódy Isolation Forest pre dataset ECG5000 pri hodnote threshold_list = 0	61
Obrázok 33 – Matica zámen metódy Isolation Forest pre dataset NAB pri hodnote threshold_list = -0,15 a train_fraction = 0,80	63

Obrázok 34 – Histogram hodnôt rozhodovacej funkcie metódy Isolation Forest pre dataset NAB pri hodnote threshold_list = -0,15 a train_fraction = 0,80.....	63
Obrázok 35 – Matica zámen metódy One-Class SVM pre dataset NASA Battery pri hodnote threshold_list = 20 a train_cycle_fraction = 0,90.....	66
Obrázok 36 – Histogram hodnôt rozhodovacej funkcie metódy One-Class SVM pre dataset NASA Battery pri hodnote threshold_list = 20 a train_cycle_fraction = 0,90....	67
Obrázok 37 – Matica zámen metódy One-Class SVM pre dataset ECG5000 pri hodnote threshold_list = -0,3.....	68
Obrázok 38 – Histogram hodnôt rozhodovacej funkcie metódy One-Class SVM pre dataset ECG5000 pri hodnote threshold_list = -0,3.....	69
Obrázok 39 – Matica zámen metódy One-Class SVM pre dataset NAB pri hodnote threshold_list = -5 a train_fraction = 0,80.....	70
Obrázok 40 – Histogram hodnôt rozhodovacej funkcie metódy One-Class SVM pre dataset NAB pri hodnote threshold_list = -5 a train_fraction = 0,80.....	71
Obrázok 41 – Matica zámen metódy Autoencoder pre dataset NASA Battery pri hodnote threshold_list = 0,002 a train_cycle_fraction = 0,90.....	73
Obrázok 42 – Histogram hodnôt rozhodovacej funkcie metódy Autoencoder pre dataset NASA Battery pri hodnote threshold_list = 0,002, train_cycle_fraction = 0,90 a seeds = 43.....	73
Obrázok 43 – Matica zámen metódy Autoencoder pre dataset ECG5000 pri hodnote threshold_list = 0,7.....	75
Obrázok 44 – Histogram hodnôt rozhodovacej funkcie metódy Autoencoder pre dataset ECG5000 pri hodnote threshold_list = 0,7.....	76
Obrázok 45 – Rekonštrukcie EKG signálov pomocou metódy Autoencoder pri hodnote threshold_list = 0,7.....	77
Obrázok 46 – Histogram hodnôt rozhodovacej funkcie metódy Autoencoder pre dataset NAB pri hodnote threshold_list = 0.00006 a train_fraction = 0,80.....	78

Obrázok 47 – Histogram hodnôt rozhodovacej funkcie metódy Autoencoder pre dataset NAB pri hodnote $\text{threshold_list} = 0,00006$ a $\text{train_fraction} = 0,80$ 79

Zoznam tabuliek

Tabuľka 1 – Výsledky metódy Isolation Forest na datasete NASA Battery	56
Tabuľka 2 – Výsledky metódy Isolation Forest na datasete ECG5000	59
Tabuľka 3 – Výsledky metódy Isolation Forest na datasete NAB	62
Tabuľka 4 – Výsledky metódy One-Class SVM na datasete NASA Battery.....	65
Tabuľka 5 – Výsledky metódy One-Class SVM na datasete ECG5000 pri rôznych hodnotách rozhodovacieho prahu.....	67
Tabuľka 6 – Výsledky metódy One-Class SVM na datasete NAB	69
Tabuľka 7 – Výsledky metódy Autoencoder na datasete NASA Battery	72
Tabuľka 8 – Výsledky metódy Autoencoder na datasete ECG5000 pri rôznych hodnotách rozhodovacieho prahu.....	74
Tabuľka 9 – Výsledky metódy Autoencoder na datasete NAB	78
Tabuľka 10 – Najlepšie konfigurácie a dosiahnuté výsledky jednotlivých metód	80

Zoznam značiek a skratiek

AE – Autoencoder (autoenkodér)

AI – Artificial Intelligence (umelá inteligencia)

Acc. – Accuracy (presnosť klasifikácie)

ANN – Artificial Neural Network (umelá neurónová sieť)

CNN – Convolutional Neural Network (konvolučná neurónová sieť)

DBSCAN – Density-Based Spatial Clustering of Applications with Noise (hlukovo odolné zhľukovanie založené na hustote)

DL – Deep Learning (hlboké učenie)

ECG – Electrocardiogram (elektrokardiogram)

F1 – F1-score (harmonický priemer metrík Precision a Recall)

FN – False Negative (anomália označená ako normálny stav)

FP – False Positive (normálny stav označený ako anomália)

GMM – Gaussian Mixture Model (gaussovský zmesový model)

iForest – Isolation Forest (izolačný les)

k-NN – k-Nearest Neighbors (metóda k najbližších susedov)

LOF – Local Outlier Factor (faktor lokálnej odľahlosti)

ML – Machine Learning (strojové učenie)

NAB – Numenta Anomaly Benchmark (benchmark pre detekciu anomálií spoločnosti Numenta)

OCSVM – One-Class Support Vector Machine (jednotriedny stroj podporných vektorov)

PCA – Principal Component Analysis (analýza hlavných komponentov)

Prec. – Precision (presnosť pozitívnych predikcií)

RBF – Radial Basis Function (radiálna bazová funkcia)

Rec. – Recall (citlivosť modelu)

RNN – Recurrent Neural Network (rekurentná neurónová sieť)

SVM – Support Vector Machine (stroj podporných vektorov)

TN – True Negative (správne identifikovaný normálny stav)

TP – True Positive (správne identifikovaná anomália)

Úvod

Diagnostika technických a priemyselných zariadení zohráva významnú úlohu pri zabezpečení ich spoľahlivej a efektívnej prevádzky. Včasná detekcia poruchových stavov umožňuje predchádzať zlyhaniu, znižovať náklady na údržbu a optimalizovať prevádzkové procesy. Moderné technické systémy však generujú rozsiahle množstvo senzorových dát, pričom poruchové stavy sa často vyskytujú iba zriedkavo. To spôsobuje, že tradičné metódy diagnostiky založené na štatistických prístupoch alebo manuálne definovaných pravidlách nie sú dostatočne presné ani flexibilné.

Strojové učenie ponúka nové možnosti pri automatickej detekcii odchýlok od normálneho správania systému. Algoritmy, ktoré sa dokážu učiť z dát, umožňujú modelovať normálne prevádzkové stavy a identifikovať neštandardné prejavy, ktoré môžu signalizovať poruchu. Výzvou však je, že v reálnych priemyselných scenároch býva k dispozícii veľa normálnych dát, ale veľmi málo príkladov porúch. Preto je potrebné využívať metódy, ktoré dokážu pracovať aj bez rozsiahlych označených datasetov, najmä unsupervised a semi-supervised prístupy.

Cieľom tejto teoretickej časti bakalárskej práce je preskúmať problematiku detekcie anomálií, analyzovať vhodné algoritmy a pripraviť metodický návrh pre praktickú implementáciu. Práca sa sústreďuje na tri metódy, ktoré sa v literatúre často používajú pri nedostatku poruchových dát: Isolation Forest, One-Class SVM a Autoencoder. Tieto metódy budú podrobne opísané a porovnané z hľadiska princípu fungovania, výhod, obmedzení a možností využitia.

Súčasťou práce je tiež výber a predspracovanie datasetov, ktoré reprezentujú rôzne typy dát – priemyselný časový rad, biomedicínsky signál a multivariantné degradačné dáta batérií. Na týchto datasetoch sú následne implementované a vyhodnotené vybrané metódy detekcie anomálií z hľadiska presnosti, citlivosti, robustnosti a praktickej použiteľnosti pri detekcii poruchových stavov.

1 Teoretické východiská

Prvá kapitola tejto práce slúži na vysvetlenie základných teoretických poznatkov, ktoré sú nevyhnutné pre pochopenie problematiky detekcie poruchových stavov pomocou metód strojového učenia.

1.1 Základy detekcie porúch a anomálií

Detekcia anomálií (nazývaná aj detekcia odľahlých hodnôt alebo porúch) je proces identifikácie vzorcov v dátach, ktoré sa výrazne odlišujú od bežného správania systému. **Anomália predstavuje** pozorovanie alebo skupinu pozorovaní, ktoré nezodpovedajú očakávanému modelu správania a môžu indikovať kritický alebo poruchový stav v systéme. [3]

V praxi môže anomália znamenať rozličné javové situácie – od jednoduchých meracích chýb až po komplexné poruchy v riadiacich systémoch alebo mechanických zariadeniach.

V oblasti priemyselnej diagnostiky je detekcia anomálií kľúčová na včasné rozpoznanie porúch v zariadeniach, čo umožňuje zvýšiť spoľahlivosť a znížiť náklady na údržbu. **Anomaly detection** je základnou súčasťou prediktívnej údržby, ktorá umožňuje identifikovať odchýlky v reálnom čase a predchádzať zlyhaniam skôr, ako ovplyvnia produkčný proces. [4]


Na rozdiel od tradičných statistických metód, ktoré predpokladajú distribučné modely dát, moderné prístupy strojového učenia umožňujú automaticky učiť vzory normálneho správania a identifikovať neštandardné odchýlky bez nutnosti explicitného nastavenia prahov. Tieto prístupy sú zvlášť efektívne v systémoch, kde je k dispozícii veľké množstvo meraných dát z normálnej prevádzky, ale len málo údajov z poruchových stavov.

1.1.1 Klasické klasifikácii porúch (pri dostatku dát)

Tradičné metódy klasifikácie porúch a prevádzkových stavov vychádzajú z predpokladu, že je k dispozícii dostatočné množstvo označených dát – teda vzoriek, ktoré reprezentujú normálny aj poruchový stav systému. Takéto metódy patria do kategórie **supervised learning**, kde sa model učí rozpoznávať triedy (napr. „OK“ a „Fault“) na základe historických meraní.


Medzi najpoužívanéjšie klasické algoritmy patria:

Decision Trees (rozhodovacie stromy) – poskytujú interpretovateľné rozhodovacie pravidlá a vhodné sú pre dáta s diskretnými aj spojitými črtami.




Obrázok 1 – Rozhodovací strom [26]

Support Vector Machines (SVM) – určujú optimálnu separačnú hranicu medzi triedami, veľmi účinné pri dobre oddeliteľných stavoch.




Obrázok 2 – Algoritmus SVM maximalizuje šírku marginu medzi dvoma triedami, znázornenými symbolmi + a -, ktoré sú oddelené separačnou hyperrovinou. [27]

k-Nearest Neighbors (k-NN) – jednoduchá metóda založená na podobnosti, ktorá klasifikuje nové vzorky podľa ich najbližších susedov v tréningových dátach.




Obrázok 3 – Vizualizácia fungovania algoritmu KNN [28]

Random Forest – ansámblová metóda, ktorá kombinuje viacero rozhodovacích stromov pre robustnejšiu klasifikáciu a zníženie preučenia.



Obrázok 4 – Schéma metódy Random Forest [29]

Neurónové siete (ANN, CNN, RNN) – využívajú sa najmä v moderných diagnostických systémoch, kde je k dispozícii veľké množstvo dát. Umožňujú zachytiť nelineárne závislosti medzi črtami a stavy systému.



Obrázok 5 – Schémy metód CNN, ANN, RNN [30]

Výhodou týchto prístupov je **vysoká presnosť** v prípadoch, keď existuje reprezentatívna databáza porúch. Ich nevýhodou však je **závislosť na množstve označených dát**, ktoré sú v praxi často obmedzené – najmä pri priemyselných zariadeniach, kde poruchy nastávajú zriedkavo.

Z tohto dôvodu sa v praxi a v tejto práci kladie dôraz na metódy **detekcie anomálií bez potreby veľkého množstva poruchových dát** (unsupervised a semi-supervised learning), ktoré sú popísané v nasledujúcich kapitolách.

1.2 Typy anomálií a poruchových stavov v technických systémoch

V technických a priemyselných systémoch sa poruchové stavy prejavujú ako **odchýlky od normálneho správania** zariadenia. Tieto odchýlky môžu byť spôsobené rôznymi faktormi – od technických chýb až po špecifické prevádzkové udalosti. Z hľadiska pôvodu môžeme rozlíšiť dva všeobecné typy anomálií [4] :

- **Neúmyselné (unintentional) anomálie** – dátové body, ktoré sa odchyľujú od normálu v dôsledku chýb alebo šumu pri zbere dát. Tieto chyby môžu byť systémové alebo náhodné, spôsobené napríklad poruchou senzora alebo ľudskou chybou pri zadávaní údajov. Neúmyselné anomálie môžu skresliť dátovú množinu a tým sťažiť presné vyhodnotenie.
- **Úmyselné (intentional) anomálie** – dátové body, ktoré sa odchyľujú od normálu v dôsledku konkrétnych akcií alebo udalostí. Tieto anomálie môžu odhaliť jedinečné výskyty alebo trendy. Napríklad náhly nárast predaja počas dovolenkového obdobia môže byť považovaný za úmyselnú anomáliu, pretože síce odchádza od typického vzoru, no je očakávaný z reálneho sveta.

Okrem týchto dvoch kategórií možno v dátach – najmä v časových radoch – identifikovať tri hlavné typy anomálií [4] :

- **Bodové (point) anomálie** – jednotlivé dátové body, ktoré výrazne vyčnievajú z celkovej množiny údajov. Tieto môžu byť úmyselné alebo neúmyselné a môžu byť výsledkom chýb, šumu alebo špecifických udalostí. Príkladom je výber z bankového účtu, ktorý je výrazne väčší než všetky predchádzajúce výbery používateľa.
- **Kontextové (contextual) anomálie** – dátové body, ktoré síce nemusia byť výrazne odlišné pri pohľade izolovane, no stávajú sa anomáliou v konkrétnom kontexte (napr. čas, prostredie, prevádzkový režim). Napríklad prudký nárast


spotreby energie v čase, keď sa obyvatelia obvykle nenachádzajú doma, by bol považovaný za kontextovú anomáliu.

- **Kolektívne (collective) anomálie** – skupina dátových instancií, ktoré spoločne vykazujú anomálne správanie, hoci jednotlivé merania môžu vyzerat' normálne. Napríklad náhla vlna sieťovej prevádzky z viacerých IP adries súčasne predstavuje kolektívnu anomáliu.

V priemyselných aplikáciách, ako sú **kyber-fyzikálne systémy** alebo **smart manufacturing**, sa všetky tieto typy anomálií môžu vyskytovať súčasne. Kým neúmyselné anomálie často signalizujú technickú chybu alebo zlyhanie senzora, úmyselné anomálie môžu obsahovať cenné informácie o reálnych zmenách v prevádzke systému. Preto je nevyhnutné, aby systémy na detekciu porúch dokázali tieto situácie rozlíšiť a správne interpretovať ich význam pre danú aplikáciu.

1.3 Úloha umelej inteligencie a strojového učenia v priemyselnej diagnostike

V posledných rokoch sa oblasť umelej inteligencie (AI) a strojové učenie (ML) stávajú kľúčovými prvkami pri diagnostike, monitorovaní a správe priemyselných systémov. Ako uvádza publikácia *Artificial Intelligence and Robotics* [1], technológie AI a robotiky sú stále viac integrované s automatizovanou prevádzkou a potrebou spoľahlivej, adaptívnej a autonómnej diagnostiky.



Obrázok 6 - Vzťah medzi AI, ML a DL (podľa Koubaa & Azar, 2021, s. 12)[2]

Význam AI/ML v priemyselnej diagnostike

Strojové učenie umožňuje spracovanie a analýzu veľkého množstva dát zo senzorov, strojov a prevádzkových procesov, čo v tradičných metódach nebolo možné s rovnakou

efektivitou. Modely ML dokážu identifikovať vzory správania zariadení, učiť sa normálne prevádzkové stavy a následne rozpoznávať odchýlky (anomálie), ktoré môžu predchádzať poruchám. [1] Ako uvádza externý zdroj, ML je schopné “transformovať surové prevádzkové dáta na akcieschopné insighty”, čo významne prispieva k prediktívnej údržbe zariadení. [5]

Priemyselné využitie a príklady

V kontexte priemyselnej diagnostiky sa AI/ML využívajú napríklad na:

- Kontinuálne monitorovanie stavu zariadení (teplota, vibrácie, prúd, tlak).
- Učenie normálneho prevádzkového správania a následné vyhodnotenie odchýlok.
- Predikciu zostávajúcej životnosti komponentov (Remaining Useful Life, RUL).
- Plánovanie údržby v prediktívnom režime namiesto alkalického alebo reakčného modelu údržby. [1][6]

Tieto aspekty sú podporené aj prácou Deep Learning for Unmanned Systems, v ktorej sa uvádza, že hlboké učenie (deep learning) a neurónové siete môžu byť aplikované v autonómnych systémoch a vretenách high-complexity údajov – čo je analogické aj v priemyselných diagnostických scenároch. [2]

Výhody a výzvy

Použitie AI/ML pri detekcii porúch prináša tieto hlavné výhody:

- Schopnosť detekovať jemné odchýlky v dátach ešte pred vznikom kritickej poruchy.
- Adaptívna schopnosť modelov učiť sa počas prevádzky a zlepšovať sa v čase.
- Možnosť spracovania komplexných a multivariantných dátových tokov. [1]

Na druhej strane je však potrebné počítať s výzvami ako: obmedzené množstvo dát z poruchových stavov (tzv. „imbalance“), potreba kvalitného predspracovania dát, interpretovateľnosť modelov a implementácia v reálnom prostredí (napr. edge zariadení). Tieto výzvy sú príznačné najmä pre priemyselné aplikácie. [4]


Pre tému tejto práce – detekciu poruchových stavov zariadení v prevádzke pomocou metód strojového učenia – je jasné, že AI/ML tvoria neoddeliteľnú teoretickú i praktickú základňu. Bez pochopenia ich princípov, možností a obmedzení by návrh, implementácia a vyhodnotenie diagnostického modelu nemohli byť úspešné.

Teoretické východiská tejto kapitoly preto pripravujú pôdu pre konkrétnu implementáciu metód v ďalších kapitolách práce.

1.4 Metódy strojového učenia pre detekciu anomálií

V tejto kapitole sú predstavené kľúčové koncepty a prístupy strojového učenia, ktoré je možné využiť na detekciu poruchových stavov (anomálií) v prevádzkových zariadeniach. Najprv sa zameriame na kategorizáciu prístupov podľa dostupnosti dát a typu učenia, následne uvádzame prehľad konkrétnych metód s ich silnými a slabými stránkami.

1.4.1 Supervised, unsupervised a semi-supervised prístupy



Obrázok 7 – Diagram supervised a unsupervised učenia. [31]

Strojové učenie pre detekciu anomálií možno rozdeliť podľa štruktúry učenia [4][7][8]:

- **Supervised prístupy:** Vyžadujú dobre označené dáta, kde sú príklady „normálneho“ aj „anomálneho“ správania. Modely sa trénujú na týchto označených množinách a následne klasifikujú nové údaje. Tieto prístupy sú vhodné pre známe typy odchýlok, ale často nie sú schopné odhaliť neznáme (nové) anomálie.
- **Unsupervised prístupy:** Nevyžadujú označené „anomálne“ dáta. Model sa učí vzor normálneho správania a identifikuje odchýlky od tohto vzoru. Tento

prístup je vhodný tam, kde chýbajú rozsiahle dáta z porúch (čo je prípad našej práce).


- **Semi-supervised prístupy:** Kombinujú malé množstvo označených dát s veľkým množstvom nezaznačených dát. Umožňujú učiť modely v situáciách s nízkou mierou porušení (imbalanced data). Tento prístup je často používaný v priemysle, keď poruchy sú zriedkavé.

1.4.2 Prehľad metód detekcie anomálií (LOF, K-Means, PCA, DBSCAN, GMM)

Metódy, ktoré budú spomenuté stručne: Local Outlier Factor (LOF), K-Means, Principal Component Analysis (PCA), DBSCAN, Gaussian Mixture Model (GMM). Nebudú hlavnou súčasťou experimentálnej časti, ale sú dôležité pre teoretický prehľad.

Local Outlier Factor (LOF) – LOF porovnáva *lokálnu hustotu* bodu s hustotou jeho susedov; body s výrazne nižšou lokálnou hustotou majú vysoké LOF a považujú sa za anomálne. Metóda je vhodná pri **negulovitých** a **heterogénnych** dátových štruktúrach, kde globálne prahy zlyhávajú. [11][12][13]


- **Výhody:** lokálna citlivosť, dobre odhaľuje anomálie v zhlukoch s rôznou hustotou.
- **Obmedzenia:** citlivosť na voľbu k (počet susedov), horšia škálovateľnosť pri veľmi veľkých dátach.



Obrázok 8 – Demonštrácia výpočtu lokálnej hustoty a identifikácie odľahlých bodov v algoritme Local Outlier Factor [32]

K-Means Clustering (pre anomálie) – K-Means vytvára K centroidov a priraduje body podľa euklidovskej vzdialenosti; anomálie sú typicky body s **veľkou reziduálnou vzdialenosťou** od najbližšieho centroidu alebo body v malých, riedkych zhhlukoch. [14][15][16]

- **Výhody:** jednoduchý a rýchly, dobre škáluje.
- **Obmedzenia:** predpoklad rovnakých, guľovitých zhhlukov, potreba zvoliť K , citlivosť na outliery (môžu „ťahat“ centroid).




Obrázok 9 – Ilustrácia fungovania algoritmu K-Means: rozdelenie dátových bodov do klastrov na základe ich podobnosti [33]

PCA (Principal Component Analysis) pre detekciu odchýlok – PCA projekciou do priestoru hlavných komponentov oddeľuje „vysvetlenú“ a „reziduálnu“ časť

variability; anomálie často vykazujú **veľké reziduá** (rekonštrukčnú chybu) alebo extrémne skóre na *minor* komponentoch. [17][18][19]

- **Výhody:** odšumovanie, zníženie dimenzie, rýchla lineárna metóda.
- **Obmedzenia:** **linearita** (nepostihne nelineárne vzťahy), voľba počtu komponentov, citlivosť na škálovanie vs tupov.




Obrázok 10 – Vizualizácia hlavných komponentov PCA: V1 zachytáva maximálnu variabilitu dát, zatiaľ čo V2 je na V1 kolmá a nesie menšiu časť variability [34]

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) –

DBSCAN identifikuje zhľuky ako oblasti s hustotou väčšou ako prah (*eps*, *min_samples*) a body mimo zhľukov označí ako **šum/anomálie**. [20][21][22]


- **Výhody:** netreba zadávať *K*, zvláda **ľubovoľné tvary zhľukov**, robustný voči outlierom.
- **Obmedzenia:** voľba *eps* a *min_samples* je kritická, ťažšie škálovanie vo veľmi vysokých dimenziách (vzdialenosti strácajú zmysel).



Obrázok 11 – Porovnanie pôvodných dát a výsledku klastrovania pomocou algoritmu DBSCAN [35]

GMM (Gaussian Mixture Model) – GMM modeluje dáta ako zmes Gaussových distribúcií a priraduje body podľa *posteriornej pravdepodobnosti*; anomálie sú body s **nízkou pravdepodobnosťou** pod natrénovaným modelom. [23][24][25]

- **Výhody:** mäkké priradenia, schopnosť modelovať **viacmódové** rozdelenia, interpretovateľné parametre.
- **Obmedzenia:** predpoklad **gaussovskej** povahy komponentov, potreba určiť počet zložiek, riziko lokálnych miním (EM algoritmus), citlivosť na inicializáciu.




Obrázok 12 – Vizualizácia troch odlišných jednorozmerných Gaussových distribúcií [36]

1.5 Vybrané metódy na porovnanie

V tejto kapitole sú podrobnejšie opísané tri vybrané metódy strojového učenia, ktoré budú implementované a porovnané v experimentálnej časti práce. Ich výber bol založený na schopnosti detegovať anomálie bez potreby rozsiahlych dát z poruchových stavov a na vhodnosti pre implementáciu na edge zariadeniach. Vybrané metódy reprezentujú tri odlišné prístupy k detekcii anomálií: stromový model (**iForest**), metódu založenú na hraniciach rozhodovania (**OCSVM**) a neurónový model (**AE**).


1.5.1 Isolation Forest

Metóda **Isolation Forest (iForest)** patrí medzi *unsupervised* algoritmy detekcie anomálií a bola predstavená Liu et al. (2008). Jej základnou myšlienkou je, že anomálne body sú v dátach jednoduchšie „izolovateľné“ než normálne. Algoritmus vytvára množinu náhodných binárnych stromov (tzv. *isolation trees*), v ktorých sa jednotlivé body dát opakovane delia podľa náhodne vybraných atribútov a prahových hodnôt.



(a) Izolácia x_i

(b) Izolácia x_o



(c) Konvergencia priemerných dĺžok ciest

Obrázok 13 – Schéma princípu izolácie anomálií v modeli iForest [9]

Panel (a) zobrazuje proces izolácie normálneho bodu x_i , ktorý sa nachádza v husto zaplnenom priestore dát. Na jeho oddelenie je potrebných viacero náhodných rozdelení (hraníc), pretože sa nachádza hlboko vo vnútri dátovej štruktúry.

Panel (b) znázorňuje izoláciu anomálneho bodu x_o , ktorý sa nachádza mimo hlavného zhluku. Na jeho oddelenie stačí len niekoľko náhodných rozdelení – je teda „ľahšie izolovateľný“.

Graf (c) v spodnej časti zobrazuje priemernú dĺžku cesty pre normálne a anomálne body v závislosti od počtu stromov. Vidieť, že anomálne body (x_o) majú kratšiu priemernú dĺžku cesty, zatiaľ čo normálne body (x_i) vyžadujú viac krokov na izoláciu. Tento rozdiel je základom pre výpočet skóre anomálie v modeli Isolation Forest.

Výhody [8]:

- nevyžaduje označené dáta
- nízka výpočtová zložitosť
- vhodná pre vysokorozmerné dáta

Nevýhody [8]:

- menej presný pri zložitých distribúciách dát
- náhodnosť môže spôsobiť miernu nestabilitu výsledkov

1.5.2 One-Class SVM

One-Class Support Vector Machine (OCSVM) je metóda založená na teórii podporných vektorov (Support Vector Machines), prispôbena na detekciu anomálií. Model sa učí len na „normálnych“ dátach a snaží sa nájsť hranicu (hyperplochu), ktorá oddeľuje normálne vzorky od zvyšku priestoru. [10]

Najčastejšie používané jadrá:


- *Gaussian (RBF)* kernel – zachytáva nelineárne hranice
- *Polynomial kernel* – pre dáta s viacrozmerným vzťahom

Výhody [3]:

- efektívna pre malé až stredne veľké dataset-y
- schopná pracovať s nelineárnymi dátami

Nevýhody [3]:

- potrebuje starostlivý výber parametrov (kernel, ν , γ)
- môže byť výpočtovo náročná



Obrázok 14 – Vizualizácia detekcie anomálií pomocou One-Class SVM [37]

1.5.3 Autoencoder

Autoencoder (AE) je typ neurónovej siete využívanej na *unsupervised learning*. Jej cieľom je naučiť sa rekonštruovať vstupné dáta cez latentnú reprezentáciu nižšej dimenzie. Sieť pozostáva z dvoch častí – **encoder** a **decoder**.

Encoder komprimuje vstupné dáta do latentného priestoru, kým decoder sa snaží zrekonštruovať pôvodný vstup. [1][2][8]

Tréning siete minimalizuje rekonstrukčnú chybu. Pri detekcii anomálií sa predpokladá, že sieť sa naučí dobre rekonštruovať „normálne“ stavy, zatiaľ čo anomálie budú mať vysokú hodnotu chyby $L(x, \hat{x})$.


Výhody:

- schopnosť učiť sa komplexné nelineárne vzťahy
- vhodný pre multivariantné a časové dáta (napr. senzory)
- možnosť nasadenia na edge zariadeniach

Nevýhody:

- potreba väčšieho množstva tréningových dát
- zložitejšie ladenie architektúry

V praxi sa autoenkóдеры často používajú v kombinácii s ďalšími metódami detekcie anomálií, ako sú One-Class SVM alebo SVDD. Takéto hybridné modely spájajú schopnosť neurónovej siete extrahovať príznaky so schopnosťou SVM oddeliť normálne a anomálne vzory v latentnom priestore.



Obrázok 15 – Všeobecná architektúra autoenkódera (AE) [38]

2 Analýza a výber dátových súborov

V tejto kapitole sa venujeme analýze dostupných dátových súborov, ktoré môžu byť použité na detekciu poruchových stavov a anomálií v technických a senzorických dátach. Keďže cieľom práce je porovnať viacero metód strojového učenia pri práci s reálnymi alebo realistickými prevádzkovými dátami, je nevyhnutné zvoliť datasety, ktoré splňajú požiadavky na kvalitu, dostupnosť, komplexnosť a relevantnosť k téme priemyselnej diagnostiky.

Najskôr definujeme **kritériá výberu datasetov**, ktoré slúžia ako metodický rámec pre objektívne posúdenie vhodnosti dostupných dát. Následne detailne predstavíme **tri vybrané datasety**, ktoré budú použité na experimentálnu časť práce – každý z nich reprezentuje odlišný typ signálu (senzorické dáta, bio-signály, inžinierske degradačné dáta), čo umožní otestovať robustnosť a generalizáciu použitých algoritmov.

V poslednej časti kapitoly uvádzame **stručný prehľad ďalších známych datasetov** používaných v oblasti detekcie anomálií. Aj keď sa v tejto práci nepoužijú priamo, slúžia ako dôležitý kontext.

2.1 Kritériá výberu datasetov

Pri výbere vhodných dátových súborov pre túto bakalársku prácu boli stanovené viaceré kritériá, ktoré reflektujú požiadavky témy – detekciu poruchových stavov pomocou metód strojového učenia bez potreby veľkého množstva poruchových dát.

Zohľadnené boli najmä tieto aspekty:

- **Dostupnosť senzorových alebo prevádzkových dát**
Dataset musí obsahovať merania z technických, biologických alebo fyzikálnych systémov, ktoré sú vhodné na analýzu anomálií (časové rady, multivariantné dáta, signály).
- **Praktická relevancia pre priemysel alebo technickú diagnostiku**
Uprednostňované boli datasety z reálnych meraní (industry, biomedical, NASA), ktorých charakter zodpovedá scenárom detekcie porúch v praxi.
- **Možnosť aplikácie zvolených metód**
Každý dataset musel byť vhodný pre všetky tri porovnávané algoritmy: *Isolation Forest*, *One-Class SVM* a *Autoencoder*.
- **Kvalita dokumentácie a dostupnosť popisu dát**
Dôležitým kritériom bola dostupnosť technickej dokumentácie, vysvetlenie atribútov a kontext prevádzky zariadenia.
- **Rozsah dát a štruktúra anomálií**
Ideálne dátové sady obsahujú buď jasne označené anomálie, alebo aspoň dlhé sekvencie normálneho správania, vhodné pre metódy semi-supervised learningu.

Na základe týchto kritérií boli vybrané tri datasety, ktoré budú použité v experimentoch tejto práce.

2.2 Použité datasety

2.2.1 Numenta Anomaly Benchmark (NAB) – Industrial Temperature Time Series

Dataset použitý v tejto diplomovej práci pochádza z benchmarkovej kolekcie **Numenta Anomaly Benchmark (NAB)**, ktorá bola vytvorená organizáciou Numenta na systematické hodnotenie algoritmov detekcie anomálií v časových radoch. Benchmark bol navrhnutý s cieľom simulovať realistické podmienky nasadenia detekčných systémov v reálnom čase, kde je dôležité identifikovať anomálie čo najskôr po ich vzniku. [52]

NAB obsahuje viacero typov dát reprezentujúcich rôzne aplikačné oblasti, napríklad:

- priemyselné senzorové merania
- metriky serverovej záťaže
- sieťovú prevádzku
- finančné časové rady
- synteticky generované signály

Každý časový rad obsahuje **referenčne označené intervaly výskytu anomálií (anomaly windows)**, ktoré umožňujú objektívne vyhodnotenie presnosti detekcie. Benchmark zároveň zavádza vlastnú metodiku hodnotenia, ktorá zohľadňuje nielen správnosť detekcie, ale aj rýchlosť reakcie algoritmu. [49]


V rámci tejto práce bol použitý konkrétny poddataset z kategórie priemyselných meraní, reprezentujúci **jednorozmerný časový rad teploty priemyselného zariadenia**. Dáta zachytávajú dynamiku správania zariadenia počas jeho prevádzky a obsahujú obdobia stabilného režimu aj úseky s výskytom anomálnych stavov.

Exploratívna analýza datasetu ukázala, že väčšina hodnôt teploty sa nachádza v intervale typickom pre normálnu prevádzku systému. Anomálie sa prejavujú najmä ako:

- náhle poklesy hodnôt
- zvýšená variabilita signálu
- krátkodobé nestabilné úseky


Dataset NAB je vhodný pre experimentálne porovnanie **unsupervised metód detekcie anomálií**, pretože umožňuje analyzovať schopnosť modelov zachytiť zmeny dynamiky signálu bez potreby rozsiahleho množstva označených poruchových dát.

V kontexte diplomovej práce predstavuje dataset NAB dôležitý experimentálny zdroj dát, ktorý umožňuje komplexné testovanie robustnosti navrhnutých modelov na reálnych časových radoch s rôznymi typmi anomálneho správania systému.




Obrázok 16 – Príklad detekcie anomálií na teplote pomocou autoenkódera. [39]

Graf znázorňuje časový priebeh teploty zariadenia spolu s referenčne označenými anomálnymi bodmi. Anomálie sa prejavujú najmä ako výrazné poklesy hodnôt alebo nestabilné úseky signálu.



Obrázok 17 – Rozdelenie hodnôt teploty v časovom rade priemyselného zariadenia [39]

Rozdelenie hodnôt teploty poukazuje na dominantný rozsah normálnych hodnôt a prítomnosť extrémnych odchýlok reprezentujúcich potenciálne anomálie.



Obrázok 18 – Detekcia anomálií v časovom rade teploty pomocou metódy One-Class SVM [39]

Graf znázorňuje body klasifikované ako anomálie pomocou metódy One-Class SVM. Metóda deteguje širší rozsah odchýlok, čo zvyšuje citlivosť detekcie, ale môže viesť aj k vyššiemu počtu falošných poplachov.

2.2.2 ECG5000 Dataset

Dataset **ECG5000** predstavuje kolekciu elektrokardiografických (EKG) signálov, ktoré zachytávajú elektrickú aktivitu srdca počas jednotlivých srdcových úderov. Dataset pochádza z oblasti medicínskej diagnostiky a je často využívaný ako benchmark pre klasifikáciu časových radov a detekciu anomálií.


Každý záznam v datasete reprezentuje **jednotlivý srdcový úder** vo forme časovej sekvencie približne 140 meraní. Dáta sú získané spracovaním dlhších EKG záznamov, ktoré boli segmentované na jednotlivé údery. Dataset obsahuje normálne aj patologické vzory, pričom anomálie súvisia najmä so zmenou tvaru signálu, deformáciou typických vĺn alebo odchýlkami v amplitúde.

Na rozdiel od technických datasetov, kde sa anomálie často prejavujú ako extrémne hodnoty, v prípade EKG datasetu ide predovšetkým o **tvarové anomálie (shape anomalies)**. To znamená, že hodnota signálu nemusí byť extrémna, ale jeho priebeh sa

líši od normálneho vzoru. Takéto vlastnosti robia dataset vhodným na testovanie metód založených na modelovaní normálneho správania, ako sú autoenkóдеры. [40]


Dataset bol v práci použitý na experimentálne overenie všetkých implementovaných metód detekcie anomálií, pričom osobitná pozornosť bola venovaná analýze správania modelu Autoencoder. Tento model sa učí reprezentáciu normálneho srdcového signálu a anomálie identifikuje na základe zvýšenej chyby rekonštrukcie.

ECG5000 dataset je vhodný pre výskum detekcie anomálií v biologických signáloch, pretože obsahuje jemné aj výrazné odchýlky od normálneho priebehu. V kontexte tejto bakalárskej práce predstavuje dataset dôležité porovnanie s priemyselnými dátami, keďže umožňuje analyzovať správanie modelov na tvarových časových radoch s odlišným charakterom anomálií.




Obrázok 19 – Normálny EKG signál [40]

Graf znázorňuje typický priebeh normálneho srdcového úderu reprezentovaný ako časový rad. Signál má relatívne stabilný tvar bez výrazných deformácií alebo náhlych odchýlok, čo je charakteristické pre normálne fungovanie srdca.




Obrázok 20 – Anomálny EKG signál [40]

Na grafe je príklad patologického EKG signálu. Je možné pozorovať deformáciu tvaru signálu a výraznejšie zmeny amplitúdy, ktoré indikujú prítomnosť anomálie.



Obrázok 21 – Rekonštrukcia normálneho EKG signálu pomocou autoenkódera [40]

Graf znázorňuje porovnanie vstupného normálneho EKG signálu a jeho rekonštrukcie pomocou autoenkódera. Rekonštruovaný signál sa výrazne podobá pôvodnému priebehu, pričom chyba rekonštrukcie zostáva nízka. To naznačuje, že model sa úspešne naučil reprezentovať typické vzory normálneho správania.



Obrázok 22 – Rekonštrukcia anomálneho EKG signálu pomocou autoenkódera [40]

Na grafe je zobrazené porovnanie vstupného anomálneho EKG signálu a jeho rekonštrukcie. V dôsledku odlišného tvaru signálu je chyba rekonštrukcie výrazne vyššia, čo umožňuje identifikovať prítomnosť anomálie.

2.2.3 NASA Battery Health Dataset

Dataset použitý v tejto práci pochádza z experimentov realizovaných v **NASA Ames Prognostics Center of Excellence (PCoE)** a obsahuje detailné merania lítiovo-iónových batériových článkov počas opakovaných cyklov nabíjania a vybíjania. Cieľom zberu dát bolo sledovanie procesu degradácie batérií až do dosiahnutia konca ich životnosti.

Dáta sú reprezentované ako **viacrozmerné časové rady**, ktoré obsahujú merania viacerých fyzikálnych veličín, napríklad:

- napätie (Voltage)
- prúd (Current)
- teplota (Temperature)
- kapacita článku (Capacity)
- čas cyklu a ďalšie prevádzkové parametre


Merania sú organizované do jednotlivých **nabíjacích a vybíjacích cyklov**, pričom pre každú batériu je zaznamenaný postupný pokles kapacity a zmeny dynamiky signálov v priebehu jej starnutia. Dataset tak umožňuje analyzovať nielen okamžité

anomálie, ale aj **dlhodobé degradačné trendy**, ktoré sú typické pre elektrochemické systémy.

Sú anomálie v tomto datasete často **postupné a kontextové**, prejavujúce sa napríklad znižovaním maximálnej kapacity, zmenou priebehu napäťových kriviek alebo zvýšenou citlivosťou na teplotu. Takéto vlastnosti robia dataset vhodným pre testovanie algoritmov schopných modelovať normálne správanie systému v čase a identifikovať odchýlky od očakávaného degradačného priebehu. [41]


V kontexte bakalárskej práce bol dataset použitý na experimentálne overenie všetkých implementovaných metód detekcie anomálií. **Autoencoder** umožňuje modelovať normálne správanie batérie v počiatočných cykloch a identifikovať nelineárne odchýlky v neskorších fázach degradácie na základe zvýšenej chyby rekonštrukcie. **One-Class SVM** je možné využiť na aproximáciu hranice medzi normálnymi a degradovanými cyklami, zatiaľ čo **Isolation Forest** dokáže identifikovať odľahlé merania alebo netypické prevádzkové stavy v rámci jednotlivých časových radov.

Význam datasetu spočíva aj v jeho širokom využití v oblasti **prognostiky zostávajúcej životnosti batérií (Remaining Useful Life – RUL)** a v modelovaní elektrochemickej degradácie. Vďaka realistickému charakteru meraní a prítomnosti komplexných trendov predstavuje dataset vhodný experimentálny základ pre analýzu robustnosti detekčných algoritmov na dátach s postupným vývojom anomálií.



Obrázok 23 – Trend elektrochemického odporu batérie počas degradácie [51]

Graf znázorňuje vývoj elektrolytického odporu (R_e) a odporu prenosu náboja (R_{ct}) v priebehu času. Postupný nárast týchto parametrov poukazuje na zhoršovanie elektrochemických vlastností batérie a predstavuje indikátor jej degradácie. Rast vnútorného odporu batérie patrí medzi typické prejavy postupných degradačných anomálií v elektrochemických systémoch.



Obrázok 24 – Pribeh vybíjacieho cyklu batérie (viacrozmerné merania) [50]

Graf znázorňuje priebeh vybraných meraní počas vybíjacieho cyklu batérie, vrátane napätia, prúdu a teploty. Je možné pozorovať charakteristický pokles napätia, zmeny teploty a stabilný priebeh vybíjacieho prúdu.

Takéto viacrozmerné časové rady umožňujú analyzovať degradačný proces a identifikovať odchýlky od normálneho správania systému. Analýza jednotlivých cyklov umožňuje zachytiť kontextové anomálie, ktoré nie sú zrejmé pri sledovaní agregovaných metrík, ako je kapacita.

2.3 Iné známe datasety pre detekciu anomálií (stručný prehľad)

V tejto podkapitole sú uvedené ďalšie známe datasetové zdroje, ktoré sa bežne používajú na výskum detekcie anomálií, ale neboli vybrané pre túto prácu.

2.3.1 Transakcie Kreditných Kariet (Credit Card Transactions – Fraud Detection)

Dataset obsahuje transakčné údaje kreditných kariet s označenými podvodnými operáciami. Vyznačuje sa výraznou nevyváženosťou dát (menej ako 1 % transakcií je podvodných), čo ho robí vhodným na testovanie algoritmov pre extrémne imbalance problémy. [42]

2.3.2 KDD Cup 1999 (detekcia narušení v sieťovej komunikácii)

Jeden z najznámejších datasetov pre detekciu narušení (intrusion detection). Obsahuje sieťovú komunikáciu rozdelenú na normálnu a rôzne typy útokov. Aj keď je historický, stále sa používa ako benchmark pre porovnanie algoritmov. [43]

2.3.3 Dataset Raketoplánu (Shuttle Dataset)

Dataset obsahuje telemetrické údaje zo systému riadenia raketoplánu, dáta sú rozdelené do siedmich tried, pričom jedna trieda predstavuje normálny prevádzkový stav a ostatné triedy reprezentujú rôzne typy odchýlok. Dataset sa často využíva v oblasti detekcie anomálií, kde sú menšinové triedy považované za anomálie. [44]

2.3.4 Dataset Arytmií (Arrhythmia Dataset)

Dataset obsahuje medicínske údaje pacientov s rôznymi typmi arytmií. Často sa používa ako referenčný dataset pre detekciu anomálií v biomedicíne, najmä v kombinácii so SVM a PCA. [45]

2.3.5 Typ Pôdneho Pokryvu (Forest Cover Type Dataset)

Dataset je pôvodne určený na klasifikáciu typu pôdneho pokryvu, ale často sa využíva aj na outlier detection, pretože obsahuje viacero skupín so špecifickými charakteristikami. [46]

2.3.6 Bezpečný Vodárenský Systém (SWaT – Secure Water Treatment)

Dataset zo skutočnej priemyselnej vodárenskej linky pozostávajúci zo stoviek senzorových meraní. Obsahuje normálnu prevádzku aj simulované kybernetické útoky. Patrí medzi najdôležitejšie datasety pre priemyselnú bezpečnosť. [47]

2.3.7 Telemetrické Dáta z Vesmírnych Misií (SMAP & MSL)

Datasety z NASA JPL obsahujú telemetrické signály z vesmírnych sond a satelitov. Sú rozsiahle, multivariantné a vhodné pre metódy založené na hlbokom učení (najmä LSTM a Autoencoder). Sú však komplexné na predspracovanie a interpretáciu. [48]

3 Návrh a implementácia riešenia

Po teoretickej analýze problematiky **detekcie anomálií** a výbere vhodných datasetov je ďalším krokom praktická realizácia navrhovaného riešenia. Cieľom tejto kapitoly je navrhnúť a implementovať experimentálny systém, ktorý umožní aplikovať vybrané **metódy strojového učenia** na detekciu poruchových stavov v rôznych typoch dát.

Praktická časť práce nadväzuje na teoretické poznatky uvedené v predchádzajúcich kapitolách, najmä na opis metód **Isolation Forest**, **One-Class SVM** a **Autoencoder**, ktoré boli identifikované ako vhodné prístupy pre detekciu anomálií v situáciách s obmedzeným množstvom dát z poruchových stavov. Implementácia týchto metód bude realizovaná v programovacom jazyku Python s využitím dostupných knižníc pre strojové učenie a spracovanie dát.

V rámci praktickej realizácie bude najskôr navrhnutá **architektúra systému detekcie anomálií**, ktorá definuje základnú štruktúru spracovania dát a jednotlivé kroky potrebné na aplikáciu modelov strojového učenia. Následne sa práca zameria na prípravu dát pre experimenty a ich úpravu do formy vhodnej pre modelovanie.

Ďalšia časť kapitoly je venovaná **implementácii vybraných algoritmov v jazyku Python**. Každá metóda bude implementovaná samostatne a aplikovaná na zvolené datasety, čo umožní analyzovať jej správanie pri detekcii anomálií v rôznych typoch dát.

Na záver kapitoly bude vykonané **porovnanie úspešnosti a výpočtovej náročnosti** jednotlivých implementovaných metód, ktoré poskytne základ pre následnú experimentálnu analýzu a hodnotenie výsledkov v ďalšej kapitole práce.

3.1 Architektúra systému detekcie anomálií

Základnou úlohou systému je spracovanie vstupných dát, ich transformácia do vhodnej reprezentácie pre modely strojového učenia a následná identifikácia anomálnych vzorov v dátach. Celý proces je možné rozdeliť do niekoľkých logických krokov, ktoré spolu tvoria **pipeline detekcie anomálií**.


Prvým krokom je získanie a načítanie **vstupných dát**. V tejto práci sú použité tri rôzne datasety, ktoré reprezentujú odlišné typy dátových štruktúr – *priemyselné senzorové merania, biomedicínske signály a multivariantné merania fyzikálnych veličín*. Táto rozmanitosť umožňuje otestovať robustnosť navrhovaného systému a overiť použiteľnosť vybraných metód v rôznych aplikačných oblastiach.

Nasledujúcim krokom je príprava dát pre **modelovanie**. V tomto štádiu sú dáta transformované do formy vhodnej pre algoritmy strojového učenia, pričom sa zohľadňuje charakter jednotlivých datasetov. Cieľom tejto fázy je *zabezpečiť konzistentnú reprezentáciu vstupných údajov*, ktorá umožní efektívne učenie modelov a spoľahlivú detekciu odchýlok.

Po príprave dát nasleduje samotná **aplikácia modelov** detekcie anomálií. V rámci navrhovaného systému sú implementované tri rôzne prístupy strojového učenia – **Isolation Forest**, **One-Class SVM** a **Autoencoder**. Každý z týchto modelov reprezentuje odlišný princíp detekcie anomálií, čo umožňuje porovnať ich vlastnosti, výpočtové nároky a schopnosť identifikovať anomálie v dátach.

Výstupom systému sú **skóre anomálií** alebo klasifikácia jednotlivých pozorovaní na normálne a anomálne stavy. Tieto výsledky následne slúžia ako základ pre **experimentálne vyhodnotenie** a porovnanie jednotlivých metód, ktoré bude realizované v nasledujúcej kapitole práce.

Navrhnutá architektúra systému teda poskytuje jednotný experimentálny rámec, ktorý umožňuje systematicky testovať a analyzovať rôzne prístupy k detekcii anomálií na dátach s odlišnou štruktúrou a charakterom.



Obrázok 25 – Architektúra systému detekcie anomálií

3.2 Predspracovanie dát, extrakcia príznakov a delenie datasetov

Predspracovanie dát predstavuje dôležitú fázu navrhovaného systému detekcie anomálií, ktorej cieľom bolo pripraviť rôzne typy datasetov do formy vhodnej pre aplikáciu metód Isolation Forest, One-Class SVM a Autoencoder. Keďže jednotlivé datasety sa líšia charakterom dát, predspracovanie bolo navrhnuté individuálne pre každý z nich.

Všeobecný postup zahŕňal načítanie dát, kontrolu kvality, úpravu formátu, vytvorenie alebo úpravu označení anomálií, extrakciu odvodených príznakov a prípravu trénovacích a testovacích množín. Modely boli trénované iba na normálnych vzorkách, zatiaľ čo testovacie množiny obsahovali normálne aj anomálne dáta.

3.2.1 Predspracovanie priemyselného datasetu (NAB)

Ako bolo uvedené v kapitole 2.2, použité datasety sa líšia svojou štruktúrou aj charakterom anomálií. Z tohto dôvodu bolo predspracovanie navrhnuté samostatne pre každý dataset.

Pri priemyselnom datasete NAB bol použitý jednorozmerný časový rad teploty zariadenia. Po načítaní dát zo súboru CSV bol časový údaj prevedený do formátu

datetime a merania boli zoradené podľa časovej osi. Následne bola vykonaná kontrola chýbajúcich hodnôt a základná štatistická analýza signálu.

Kedže dataset NAB obsahuje známe intervaly výskytu anomálií (anomaly windows), bol vytvorený binárny atribút **y_true**, kde hodnota 1 reprezentuje anomáliu a hodnota 0 normálny stav.

Zo surového signálu boli následne extrahované nové príznaky pomocou klzavého okna veľkosti 50 meraní:

- prvá diferenciácia signálu,
- klzavý priemer,
- klzavá smerodajná odchýlka,
- lokálne minimum,
- lokálne maximum.

Riadky s neúplnými hodnotami, ktoré vznikli po výpočte diferenciácie a klzavých štatistík, boli odstránené. Výsledkom bol dataset **industrial_machine_features_labeled.csv**, ktorý obsahuje pôvodnú hodnotu signálu, odvodené časové príznaky a označenie anomálií.

Ukážka extrahovaných príznakov a označení anomálií z datasetu NAB

timestamp	value	y_true	diff1	roll_mean	roll_std	roll_min	roll_max
2013-12-03	85.345	0	0.161	81.307	2.262	73.967	85.345
2013-12-03	84.672	0	-0.673	81.521	2.05	74.936	85.345
2013-12-03	85.303	0	0.631	81.729	1.888	76.124	85.345
2013-12-03	84.349	0	-0.954	81.893	1.743	78.141	85.345
2013-12-03	84.556	0	0.207	82.022	1.697	78.71	85.345

Obrázok 26 – Ukážka extrahovaných príznakov z priemyselného časového radu

Tabuľka znázorňuje ukážku odvodených príznakov vytvorených zo surového teplotného signálu pomocou diferenciácie a klzavých štatistík spolu s označením anomálií. Tieto príznaky umožňujú zachytiť lokálnu dynamiku správania systému a zlepšujú schopnosť modelov detegovať anomálie.

Jednotlivé stĺpce reprezentujú rôzne charakteristiky správania časového radu:

- **timestamp** – časová značka merania,
- **value** – pôvodná nameraná hodnota teploty v danom časovom okamihu,
- **y_true** – binárne označenie anomálie (1 – anomália, 0 – normálny stav),
- **diff1** – prvá diferenciácia signálu, ktorá vyjadruje zmenu hodnoty medzi dvoma po sebe idúcimi meraniami,
- **roll_mean** – klzavý priemer vypočítaný v rámci definovaného časového okna,
- **roll_std** – klzavá smerodajná odchýlka, ktorá vyjadruje mieru variability alebo nestability signálu,

- **roll_min** – minimálna hodnota signálu v rámci klzavého okna,
- **roll_max** – maximálna hodnota signálu v rámci klzavého okna.

Kombinácia týchto príznakov umožňuje zachytiť nielen absolútnu hodnotu merania, ale aj dynamiku zmien signálu, čo je dôležité pri detekcii anomálií v priemyselných časových radoch.

Pri experimentoch bol dataset rozdelený chronologicky. Trénovacia časť obsahovala iba normálne vzorky, zatiaľ čo testovacia časť obsahovala normálne aj anomálne vzorky. Pred aplikáciou modelov bola na vstupné príznaky použitá štandardizácia pomocou metódy **StandardScaler**.

3.2.2 Predspracovanie datasetu ECG5000

V nadväznosti na opis datasetu ECG5000 v kapitole 2.2.2 bolo predspracovanie zamerané na prípravu EKG signálov pre modely detekcie anomálií.

Dataset ECG5000 obsahuje jednotlivé srdcové cykly reprezentované ako časové rady s pevnou dĺžkou. V experimentoch bol použitý pôvodný preddefinovaný split datasetu, pričom súbor **ECG5000_TRAIN** slúžil na vytvorenie trénovacej množiny a súbor **ECG5000_TEST** bol použitý na testovanie modelov.

Pôvodné triedy boli transformované na binárnu reprezentáciu. Trieda 1 bola považovaná za normálny srdcový rytmus, zatiaľ čo triedy 2 až 5 boli označené ako anomálne. Táto informácia bola použitá iba na vyhodnotenie modelov.

Trénovacia množina obsahovala výlučne normálne EKG cykly. Testovacia množina obsahovala normálne aj anomálne vzorky.

Pred trénovaním modelov bola vykonaná štandardizácia vstupných dát pomocou Z-normalizácie. Priemer a smerodajná odchýlka boli vypočítané z normálnych trénovacích vzoriek a následne použité na transformáciu trénovacích aj testovacích dát. Tým sa zabezpečilo, že modely využívali iba informácie dostupné v normálnej trénovacej množine.

Ukážka z-normalizovaných EKG cyklov a binárnej značky anomálie

0	1	2	3	4	5	6	7	8	9	y_is_anomaly
-0.113	-2.837	-3.787	-4.365	-4.392	-3.487	-2.189	-1.825	-1.255	-0.479	0.0
-1.105	-4.011	-4.301	-4.523	-4.037	-3.246	-1.572	-0.996	-0.757	0.042	0.0
-0.569	-2.603	-3.888	-4.601	-4.202	-3.163	-1.749	-1.496	-1.188	-0.396	0.0
0.492	-1.921	-3.629	-4.334	-4.283	-3.895	-3.004	-1.677	-1.339	-0.969	0.0
0.803	-0.877	-2.393	-3.988	-4.354	-3.816	-2.544	-1.79	-1.6	-0.756	0.0

Obrázok 27 – Ukážka štandardizovaných EKG cyklov s binárnou anotáciou anomálie

Tabuľka znázorňuje ukážku EKG cyklov po aplikácii štandardizácie. Jednotlivé stĺpce predstavujú postupné vzorky EKG signálu v rámci jedného srdcového cyklu. Hodnoty vyjadrujú štandardizované vzorky EKG signálu, pričom priemer a smerodajná odchýlka boli vypočítané výlučne z normálnych tréningových dát.

Stĺpec **y_is_anomaly** predstavuje binárnu značku anomálie, kde hodnota 0 označuje normálny srdcový rytmus a hodnota 1 reprezentuje anomálny cyklus. Táto značka bola použitá výlučne na vyhodnotenie úspešnosti modelov a nebola zahrnutá do procesu učenia.

3.2.3 Predspracovanie datasetu NASA Battery

Ako bolo uvedené v kapitole 2.2.3, dataset NASA Battery obsahuje multivariantné merania lítiovo-iónových batérií počas vybíjajúcich cyklov. Pri predspracovaní bol kladený dôraz na zachovanie fyzikálneho významu meraných veličín a zároveň na vytvorenie príznakov umožňujúcich zachytiť postupnú degradáciu batérie.

Najskôr boli načítané metadáta obsahujúce informácie o jednotlivých cykloch. Z celého datasetu boli vybrané iba vybíjacie cykly (discharge), ktoré sú najvhodnejšie na analýzu stavu batérie. Následne boli údaje z jednotlivých CSV súborov zlúčené do jednej dátovej tabuľky.

Okrem pôvodných meraní boli vytvorené aj odvodené príznaky opisujúce dynamiku zmien jednotlivých veličín. Pre napätie, prúd a teplotu boli vypočítané prvé diferenciácie (**V_diff1**, **I_diff1**, **T_diff1**), ktoré vyjadrujú zmenu hodnoty medzi dvoma po sebe nasledujúcimi meraniami.

Na lepšie zachytenie lokálneho správania signálov boli následne pomocou klzavého okna vytvorené štatistické príznaky. Pre napätie boli vypočítané klzavý priemer, smerodajná odchýlka, minimum a maximum (**V_roll_mean**, **V_roll_std**, **V_roll_min**, **V_roll_max**). Pre prúd a teplotu boli vytvorené príznaky **I_roll_mean**, **I_roll_std**, **T_roll_mean** a **T_roll_std**.

Riadky s neúplnými hodnotami vzniknutými pri výpočte diferenciácií a klzavých štatistík boli odstránené.

Označenie anomálnych cyklov bolo realizované na základe kapacity batérie. Pre každý vybíjací cyklus bola známa hodnota **Capacity**, ktorá predstavuje aktuálnu kapacitu článku. Za anomálne boli označené tie cykly, ktorých kapacita bola nižšia ako **20.** percentil kapacity v rámci celého datasetu. Výsledné označenie bolo uložené do atribútu **y_true_file**, kde hodnota 1 reprezentuje anomálny stav a hodnota 0 normálny stav.

Výsledkom predspracovania bol dataset **nasa_battery_features_rolling.csv** obsahujúci pôvodné merania, odvodené príznaky, informáciu o kapacite batérie, označenie typu cyklu a identifikátor zdrojového súboru (**source_file**).

Ukážka multivariantných sensorových dát batérie počas vybíjania

Voltage_measured	Current_measured	Temperature_measured	Time	Capacity	y_true_file
4.247	0.0	6.213	0.0	1.674	0.0
4.247	-0.001	6.234	9.36	1.674	0.0
4.039	-0.995	6.25	23.281	1.674	0.0
4.02	-0.997	6.302	36.406	1.674	0.0
4.005	-0.993	6.362	49.625	1.674	0.0

Obrázok 28 – Ukážka multivariantných sensorových dát batérie počas vybíjania s doplnenou kapacitou a anotáciou cyklu

Tabuľka znázorňuje ukážku pôvodných sensorových meraní batérie počas vybíjacieho cyklu spolu s hodnotou kapacity a označením typu cyklu. Z týchto veličín boli následne vytvorené odvodené príznaky použité pri trénovaní modelov detekcie anomálií.

Jednotlivé stĺpce reprezentujú základné a odvodené charakteristiky správania batérie:

- **Voltage_measured** – namerané napätie batérie,
- **Current_measured** – nameraný prúd počas vybíjania,
- **Temperature_measured** – teplota batérie,
- **Time** – čas od začiatku vybíjacieho cyklu,
- **Capacity** – aktuálna kapacita batérie,
- **y_true_file** – označenie typu cyklu (normálny/anomálny).

Kombinácia pôvodných a odvodených príznakov umožňuje modelom zachytiť nielen okamžité hodnoty fyzikálnych veličín, ale aj ich vzájomné vzťahy a vývoj v čase, čo je dôležité pri identifikácii degradačných zmien a anomálneho správania batérií.

Pri experimentoch bolo delenie dát realizované na úrovni celých vybíjacích cyklov podľa atribútu **source_file**. Takýto postup zabráňuje tomu, aby sa merania z rovnakého cyklu nachádzali súčasne v trénovacej aj testovacej množine. Modely boli trénované iba na normálnych cykloch, zatiaľ čo testovacia množina obsahovala normálne aj anomálne cykly. Pred aplikáciou modelov bola na vstupné príznaky použitá štandardizácia pomocou metódy **StandardScaler**.

Zhrnutie predspracovania:

Predspracovanie bolo prispôsobené charakteru jednotlivých datasetov. Pri priemyselných dátach NAB sa kládol dôraz na extrakciu časových príznakov z jednorozmerného signálu, pri datasete ECG5000 na zachovanie tvaru EKG cyklov a pri batériových dátach NASA Battery na vytvorenie multivariantných a odvodených príznakov zachytávajúcich degradačné správanie batérie. Takto pripravené datasety umožňujú komplexné experimentálne porovnanie metód detekcie anomálií na rôznych typoch dát.

3.3 Implementácia metód v jazyku Python

Implementácia metód detekcie anomálií bola realizovaná v programovacom jazyku Python v prostredí Anaconda Jupyter Notebook, ktoré umožňuje interaktívnu prácu s dátami, vizualizáciu výsledkov a experimentovanie s rôznymi modelmi.

Na implementáciu boli použité štandardné knižnice pre strojové učenie a spracovanie dát:

- **pandas** – manipulácia s dátovými tabuľkami
- **numpy** – numerické operácie
- **scikit-learn** – implementácia klasických algoritmov strojového učenia
- **tensorflow / keras** – implementácia neurónových sietí (Autoencoder)
- **matplotlib** – vizualizácia výsledkov

Pre zabezpečenie objektívneho porovnania boli pre všetky metódy použité rovnaké datasety, rovnaký spôsob rozdelenia dát a identické hodnotiace metriky. Modely boli trénované výlučne na normálnych dátach, zatiaľ čo testovacie množiny obsahovali normálne aj anomálne vzorky. Tento prístup zodpovedá reálnym podmienkam priemyselnej diagnostiky, kde sú poruchové stavy zriedkavé a rozsiahle označené datasety anomálií zvyčajne nie sú k dispozícii.

Pri experimentoch, v ktorých bolo rozdelenie dát realizované náhodným výberom vzoriek, boli výsledky vyhodnotené na základe viacerých nezávislých behov s rôznymi hodnotami parametra **random seed**.

Celý proces implementácie zahŕňal:

1. načítanie a prípravu dát,
2. rozdelenie dát na trénovaciu a testovaciu časť,
3. trénovanie modelu na normálnych dátach,
4. výpočet skóre anomálie,

5. vyhodnotenie pomocou metrík Accuracy, Precision, Recall a F1-score.

3.3.1 Implementácia metódy Isolation Forest

Metóda Isolation Forest bola implementovaná pomocou triedy **IsolationForest** z knižnice **scikit-learn**. Počas experimentov boli testované rôzne konfigurácie parametrov modelu, najmä počet stromov (**n_estimators**) a parameter **contamination**, ktorý určuje predpokladaný podiel anomálií v dátach.

Po natrénovaní modelu boli pre testovacie vzorky vypočítané skóre anomálie a následne boli vzorky klasifikované ako normálne alebo anomálne. Konkrétne hodnoty použitých parametrov a dosiahnuté výsledky sú uvedené v kapitole 4.

Na základe vypočítaných skóre anomálie bola následne aplikovaná rozhodovacia hranica (**threshold**), ktorá určovala, či bude vzorka klasifikovaná ako normálna alebo anomálna. Počas experimentov boli testované rôzne hodnoty 'threshold' s cieľom analyzovať ich vplyv na presnosť detekcie anomálií.

Výhodou tejto implementácie je nízka výpočtová náročnosť a schopnosť efektívne pracovať aj s rozsiahlymi datasetmi. Nevýhodou je citlivosť na nastavenie parametra contamination, ktorý môže výrazne ovplyvniť počet detegovaných anomálií.

3.3.2 Implementácia metódy One-Class SVM

Metóda One-Class SVM bola implementovaná pomocou triedy **OneClassSVM** z knižnice **scikit-learn**. Model bol trénovaný výhradne na normálnych dátach s cieľom vytvoriť rozhodovaciu hranicu opisujúcu bežné správanie systému. Následne boli testovacie vzorky klasifikované podľa ich vzdialenosti od naučenej hranice.

Počas experimentov boli testované rôzne konfigurácie parametrov **nu** a **gamma**, ktoré ovplyvňujú tvar rozhodovacej hranice a citlivosť modelu na anomálie. Po výbere najvhodnejších konfigurácií boli vykonané finálne experimenty s rôznymi hodnotami rozhodovacieho prahu **threshold**.

Podrobné výsledky jednotlivých konfigurácií sú uvedené v kapitole 4. Hlavnou výhodou metódy One-Class SVM je schopnosť vytvoriť presnú hranicu normálneho správania systému. Nevýhodou sú vyššie výpočtové nároky pri práci s veľkými datasetmi.

3.3.3 Implementácia metód Autoencoder

Autoencoder bol implementovaný pomocou knižníc **TensorFlow** a **Keras**. Ide o neurónovú sieť pozostávajúcu z enkódera a dekódera, ktorá sa učí rekonštruovať vstupné dáta. Model bol trénovaný výlučne na normálnych vzorkách, pričom predpokladom je, že normálne dáta dokáže rekonštruovať s nízkou chybou, zatiaľ čo anomálne vzorky vykazujú vyššiu rekonštrukčnú chybu.

Počas návrhu modelu bolo testovaných viacero architektúr neurónovej siete s rôznymi rozmermi latentného priestoru, počtom neurónov v skrytých vrstvách a tréningovými parametrami. Na základe experimentálnych výsledkov bola pre každý dataset vybraná najvhodnejšia konfigurácia.

Po natrénovaní modelu bola pre každú testovaciu vzorku vypočítaná rekonštrukčná chyba, ktorá slúžila ako skóre anomálie. Následne boli pomocou rôznych hodnôt rozhodovacieho prahu identifikované anomálne vzorky. Podrobné výsledky sú uvedené v kapitole 4.

Výhodou Autoencoderu je schopnosť zachytiť komplexné nelineárne vzťahy v dátach. Nevýhodou je vyššia časová náročnosť tréningu a potreba vhodného návrhu architektúry neurónovej siete.

3.4 Porovnanie výpočtovej náročnosti metód

Porovnanie výpočtovej náročnosti jednotlivých metód je dôležité najmä z hľadiska ich praktického nasadenia v priemyselných systémoch, kde sú často obmedzené výpočtové zdroje a požiadavky na rýchlosť spracovania dát.

V tejto práci boli porovnávané tri metódy detekcie anomálií: **Isolation Forest**, **One-Class SVM** a **Autoencoder**, pričom každá z nich má odlišné nároky na čas a pamäť.

Metóda **Isolation Forest** patrí medzi výpočtovo najefektívnejšie prístupy. Jej zložitosť rastie približne lineárne s počtom vzoriek, keďže využíva náhodné podmnožiny dát a relatívne plytké rozhodovacie stromy. Vďaka tomu je vhodná aj pre väčšie datasety a umožňuje rýchle trénovanie aj predikciu.

Naopak, metóda **One-Class SVM** je výpočtovo najnáročnejšia. Jej zložitosť závisí od počtu trénovacích vzoriek a môže rásť kvadraticky až kubicky. Z tohto dôvodu bolo v experimentoch potrebné obmedziť veľkosť trénovacej množiny. Tento prístup síce umožňuje dosiahnuť presnú hranicu medzi normálnymi a anomálnymi dátami, avšak za cenu vyšších výpočtových nárokov.

Autoencoder predstavuje kompromis medzi týmito dvoma prístupmi. Výpočtová náročnosť závisí najmä od architektúry neurónovej siete a počtu tréningových epoch. Tréning modelu je časovo náročnejší ako pri Isolation Forest, avšak po natrénovaní je predikcia relatívne rýchla. Výhodou je schopnosť spracovať veľké množstvo dát pomocou optimalizačných algoritmov a paralelizácie na GPU.

Z hľadiska pamäťových nárokov je **One-Class SVM** najnáročnejšia metóda, keďže uchováva podporné vektory. **Isolation Forest** má nižšie pamäťové nároky vďaka stromovej štruktúre a **Autoencoder** vyžaduje pamäť najmä na uloženie váh neurónovej siete.

Na základe uvedeného porovnania je možné povedať, že:

- **Isolation Forest** je najvhodnejší pre rýchle a škálovateľné riešenia,
- **One-Class SVM** poskytuje presné výsledky, ale za cenu vysokej výpočtovej náročnosti,
- **Autoencoder** je flexibilná metóda vhodná pre komplexné dáta, avšak vyžaduje viac času na tréning.

Výber vhodnej metódy preto závisí od konkrétnej aplikácie, veľkosti datasetu a dostupných výpočtových zdrojov.

4 Experimentálne výsledky a porovnanie metód

Táto kapitola je zameraná na prezentáciu a analýzu experimentálnych výsledkov získaných pri aplikácii vybraných metód detekcie anomálií. Cieľom je zhodnotiť výkonnosť jednotlivých modelov na rôznych datasetoch a porovnať ich schopnosť identifikovať anomálne vzorky.

V kapitole sú postupne uvedené nastavenia experimentov, použité metriky hodnotenia, výsledky pre jednotlivé metódy a ich následné porovnanie. Na základe získaných výsledkov je tiež diskutovaná vhodnosť jednotlivých metód pre praktické využitie v priemyselnom prostredí.

4.1 Nastavenie experimentov

Experimenty boli navrhnuté tak, aby umožnili objektívne porovnanie troch vybraných metód detekcie anomálií: **Isolation Forest**, **One-Class SVM** a **Autoencoder**. Všetky metódy boli testované na troch datasetoch s odlišným charakterom dát –

priemyselnom datasete NAB, biomedicínskom datasete ECG5000 a multivariačnom datasete NASA Battery.

Základná experimentálna metodika bola rovnaká pre všetky testované metódy. Modely boli trénované výlučne na dátach reprezentujúcich normálne správanie systému, zatiaľ čo anomálne vzorky boli použité iba na testovanie a následné vyhodnotenie výsledkov. Tento prístup zodpovedá reálnym podmienkam detekcie poruchových stavov, kde sú dáta z normálnej prevádzky dostupné vo výrazne väčšom množstve ako dáta reprezentujúce poruchové situácie.

Pri experimentoch boli použité datasety pripravené postupom opísaným v kapitole 3.2. Pri datasete NAB boli využité príznaky vytvorené z teplotného časového radu pomocou diferenciácie a kľzavých štatistík. Dataset ECG5000 pozostával zo štandardizovaných EKG cyklov pevnej dĺžky. Pri datasete NASA Battery boli použité multivariačné senzorové príznaky opisujúce stav batérie počas vybíjajúcich cyklov vrátane odvodených charakteristík získaných pomocou kľzavých okien.

Pri metóde Isolation Forest boli analyzované rôzne kombinácie parametrov **n_estimators** a **contamination**. Okrem týchto parametrov bol skúmaný aj vplyv rozhodovacieho prahu aplikovaného na skóre anomálie.

Pri metóde One-Class SVM boli testované rôzne konfigurácie parametrov **nu** a **gamma** pri použití RBF jadra. Po výbere vhodných konfigurácií boli realizované finálne experimenty s rôznymi hodnotami rozhodovacieho prahu.

Pri metóde Autoencoder boli testované viaceré architektúry neurónovej siete, najmä rôzne veľkosti latentného priestoru, počty neurónov v skrytých vrstvách, veľkosti dávky pri tréningu a rýchlosti učenia. Po natrénovaní modelu bola rekonštrukčná chyba použitá ako skóre anomálie a výsledná klasifikácia bola realizovaná pomocou rozhodovacieho prahu.

Pri experimentoch s náhodným rozdelením dát boli výsledky vyhodnotené na základe viacerých nezávislých behov s rôznymi hodnotami parametra **random seed**, aby sa znížil vplyv náhodného výberu dát na výsledné metriky.

Výsledky jednotlivých experimentov boli ukladané do samostatných priečinkov obsahujúcich tabuľky výsledkov, konfúzne matice a grafické výstupy. Tieto výstupy slúžili na následnú analýzu správania modelov a porovnanie ich úspešnosti pri detekcii anomálií.

4.2 Metriky hodnotenia (Precision, Recall, atď.)

Pre hodnotenie kvality modelov detekcie anomálií boli použité štandardné metriky binárnej klasifikácie. Keďže anomálie predstavujú iba menšinovú časť dát, samotná celková úspešnosť klasifikácie neposkytuje dostatočný obraz o kvalite modelu. Z tohto dôvodu bolo hodnotenie založené na kombinácii viacerých metrík.

Metrika **Accuracy** vyjadruje podiel správne klasifikovaných vzoriek z celkového počtu testovaných vzoriek. Poskytuje všeobecný pohľad na úspešnosť modelu, avšak pri nevyvážených dátach môže viesť k nadhodnotenému hodnoteniu výsledkov.

Metrika **Precision** vyjadruje podiel správne identifikovaných anomálií z celkového počtu vzoriek označených modelom ako anomálne. Vysoká hodnota tejto metriky znamená nízky počet falošne pozitívnych detekcií.

Metrika **Recall** vyjadruje schopnosť modelu odhaliť skutočné anomálie. Predstavuje podiel správne identifikovaných anomálií z celkového počtu anomálnych vzoriek prítomných v dátach. V kontexte detekcie poruchových stavov ide o jednu z najdôležitejších metrík, pretože neodhalená anomália môže predstavovať potenciálne riziko alebo poruchu systému.

F1-skore predstavuje harmonický priemer metrík Precision a Recall. Poskytuje vyvážené hodnotenie modelu v prípadoch, keď je potrebné súčasne zohľadniť presnosť detekcie aj schopnosť zachytiť čo najväčší počet anomálií.

Okrem uvedených metrík boli pri analýze výsledkov využité aj konfúzne matice a histogramy skóre anomálií. Tieto vizualizácie umožnili podrobnejšie posúdiť správanie modelov a analyzovať vplyv rôznych hodnôt rozhodovacích prahov na výslednú klasifikáciu.

4.3 Výsledky pre jednotlivé metódy

V tejto podkapitole sú prezentované výsledky jednotlivých metód detekcie anomálií aplikovaných na vybrané datasety. Pre každú metódu sú uvedené výsledky dosiahnuté pri rôznych nastaveniach parametrov, pričom je analyzovaný ich vplyv na kvalitu detekcie.

Výsledky sú prezentované vo forme tabuliek a grafov, ktoré umožňujú porovnanie výkonnosti modelov z hľadiska metrík Accuracy, Precision, Recall a F1-skore.

4.3.1 Výsledky pre Isolation Forest

Tabuľky č. 1–3 prezentujú výsledky detekcie anomálií pomocou algoritmu Isolation Forest na datasetoch NASA Battery, NAB a ECG5000. V ľavej časti tabuliek sú uvedené použité konfigurácie modelu a hodnoty rozhodovacieho prahu (*threshold*), zatiaľ čo pravá časť obsahuje hodnotenie modelu pomocou metrík Accuracy, Precision, Recall a F1-skóre.

Počas úvodných experimentov boli testované rôzne hodnoty parametrov *n_estimators* a *contamination*. Na základe dosiahnutých výsledkov bola pre ďalšie experimenty zvolená konfigurácia *n_estimators* = **300** a *contamination* = "**auto**", ktorá poskytovala stabilné výsledky na analyzovaných datasetoch. Pri experimentoch s pevným rozdelením dát bol použitý parameter **random_state** = **42**. V prípadoch, kde bolo rozdelenie dát realizované náhodným výberom vzoriek, boli experimenty opakované s viacerými hodnotami parametra **random seed**.

Po výbere vhodných hodnôt parametrov *nu* a *gamma* boli realizované experimenty s rôznymi hodnotami rozhodovacieho prahu (*threshold*). Cieľom bolo analyzovať vplyv nastavenia prahu na výsledné metriky a nájsť vhodný kompromis medzi Precision a Recall.

Pri datasete NASA Battery bolo rozdelenie dát realizované na úrovni celých vybíjajúcich cyklov reprezentovaných atribútom *source_file*. Experiment bol opakovaný päťkrát s rôznymi hodnotami parametra *seed* (42–46) a výsledné metriky predstavujú priemerné hodnoty zo všetkých behov. Pri datasete NAB bolo použité chronologické rozdelenie časového radu v pomere 80 % pre tréning a 20 % pre testovanie. Pri datasete ECG5000 bol využitý pôvodný preddefinovaný split TRAIN/TEST poskytnutý autorom datasetu.

V tabuľkách sú zelenou farbou označené najlepšie dosiahnuté výsledky v rámci príslušného datasetu.

Výsledky metódy Isolation Forest na datasete NASA Battery


Tabuľka 1 – Výsledky metódy Isolation Forest na datasete NASA Battery

Podiel dát	<i>Threshold</i>	Accuracy %	Precision %	Recall %	F1-score %
0.80	0.0	75.28	85.84	60.57	71.0
	0.065	80.69	75.16	92.14	82.67
	0.08	77.21	69.83	96.47	80.95
0.90	0.0	70.9	92.24	61.59	73.82
	0.065	85.28	85.58	94.09	89.54
	0.08	83.32	81.78	96.93	88.65

Tabuľka 1 prezentuje výsledky metódy Autoencoder na datasete NASA Battery. Uvedené hodnoty predstavujú priemer z piatich nezávislých behov realizovaných s rôznymi hodnotami parametra *seeds*. Počas experimentov boli testované rôzne hodnoty parametra *train_cycle_fraction* a rozhodovacieho prahu *threshold_list*.


Najlepšie výsledky boli dosiahnuté pri konfigurácii *train_cycle_fraction* = **0,90** a *threshold_list* = **0,065**. Model v tomto prípade dosiahol hodnoty Accuracy 85,28 %, Precision 85,58 %, Recall 94,09 % a F1-skóre 89,54 %. Táto konfigurácia poskytla najlepší kompromis medzi schopnosťou zachytiť anomálne cykly a počtom nesprávne označených normálnych vzoriek.

Z tabuľky je možné pozorovať, že zvýšenie hodnoty *threshold* z 0,0 na 0,065 viedlo k výraznému zlepšeniu metriky Recall. Model označoval za anomálne väčší počet vzoriek, vďaka čomu dokázal identifikovať väčšinu degradovaných cyklov batérie. Pri ďalšom zvýšení prahu na hodnotu 0,08 síce Recall mierne vzrástol až na 96,93 %, avšak súčasne došlo k poklesu metrík Accuracy, Precision a F1-skóre v dôsledku vyššieho počtu falošne pozitívnych klasifikácií.



Obrázok 29 – Matica zámen metódy Isolation Forest pre dataset NASA Battery pri hodnote $\text{threshold_list} = 0,065$ a $\text{train_cycle_fraction} = 0,90$

Priemerná matica zámen pre najlepšiu konfiguráciu ($\text{threshold_list} = 0,065$) dosiahla hodnoty $TN = 3383,8$, $FP = 1616,2$, $FN = 591,4$ a $TP = 9408,6$. To znamená, že model správne identifikoval približne 94 % anomálnych vzoriek, pričom nesprávne označil približne 32 % normálnych vzoriek ako anomálie. Vysoká hodnota Recall naznačuje, že model je vhodný najmä v situáciách, kde je prioritou zachytiť čo najväčší počet potenciálnych porúch aj za cenu zvýšeného počtu falošných poplachov.



Obrázok 30 – Histogram hodnôt rozhodovacej funkcie metódy Isolation Forest pre dataset NASA Battery pri hodnote $\text{threshold_list} = 0,065$, $\text{train_cycle_fraction} = 0,90$ a $\text{seed} = 43$

Histogram hodnôt rozhodovacej funkcie zobrazuje rozdelenie skóre normálnych a anomálnych vzoriek. Normálne cykly sa koncentrujú prevažne v oblasti vyšších hodnôt skóre približne od 0,07 do 0,13, zatiaľ čo anomálne cykly vykazujú širšie rozdelenie a často dosahujú nižšie hodnoty skóre. Vertikálna čiara predstavuje hodnotu $\text{threshold} = 0,065$, ktorá určuje hranicu medzi normálnou a anomálnou triedou. Napriek pomerne dobrému oddeleniu oboch skupín je možné pozorovať ich čiastočné prekrytie v oblasti približne od 0,03 do 0,07, čo vysvetľuje vznik falošne pozitívnych a falošne negatívnych klasifikácií.

Za účelom podrobnejšieho preskúmania boli analyzované konkrétne súbory 00051.csv, 00133.csv, 00043.csv, 00107.csv a 00545.csv. Súbory 00051.csv a 00133.csv boli podľa označenia datasetu klasifikované ako anomálne, avšak model ich často vyhodnocoval ako normálne. Analýza ukázala, že ich priemerné hodnoty napätia a teploty boli veľmi podobné normálnym cyklom:

- 00051.csv: priemerné napätie $\approx 3,651$ V, priemerná teplota $\approx 7,19$ °C
- 00133.csv: priemerné napätie $\approx 3,449$ V, priemerná teplota $\approx 8,05$ °C
- 00545.csv: priemerné napätie $\approx 3,407$ V, priemerná teplota $\approx 8,23$ °C
- 00107.csv: priemerné napätie $\approx 3,382$ V, priemerná teplota $\approx 8,51$ °C
- 00043.csv: priemerné napätie $\approx 3,433$ V, priemerná teplota $\approx 8,32$ °C

Napriek podobnosti uvedených príznakov boli cykly 00051.csv a 00133.csv označené ako anomálne na základe hodnoty kapacity batérie:

- 00051.csv: Capacity = 0,0

- 00133.csv: Capacity = 0,0

Na porovnanie normálne cykly dosahovali podstatne vyššie hodnoty kapacity:

- 00545.csv: Capacity = 1,251988
- 00107.csv: Capacity = 1,161535
- 00043.csv: Capacity = 1,349743

Zároveň bolo zistené, že maximálna hodnota kapacity v skupine anomálnych cyklov bola približne 1,0518, zatiaľ čo minimálna hodnota kapacity v skupine normálnych cyklov bola približne 1,0533. Rozdelenie na normálne a anomálne cykly bolo teda realizované jednoznačne bez vzájomného prekrytia.

Na základe vykonanej analýzy možno konštatovať, že časť anomálnych cyklov vykazovala veľmi podobné hodnoty napätia, prúdu a teploty ako normálne cykly, hoci z pohľadu kapacity už boli považované za degradované. Degradácia batérie sa preto v niektorých prípadoch prejavila predovšetkým znížením kapacity a skrátením času vybíjania, zatiaľ čo vo vybraných vstupných príznakoch nebola dostatočne výrazná na jednoznačné rozlíšenie všetkých anomálnych cyklov. Táto skutočnosť predstavovala významnú výzvu pre všetky testované metódy detekcie anomálií.

Výsledky metódy Isolation Forest na datasete ECG5000

Tabuľka 2 – Výsledky metódy Isolation Forest na datasete ECG5000


<i>Threshold</i>	Accuracy %	Precision %	Recall %	F1-score %
0.0	93.42	90.09	94.61	92.29
0.025	93.84	87.78	98.99	93.05
0.05	91.62	83.42	99.68	90.83

Tabuľka 2 prezentuje výsledky metódy Isolation Forest na datasete ECG5000. Hodnoty metrík sú uvedené pre tri rôzne hodnoty rozhodovacieho prahu (*threshold*): 0, 0,025 a 0,05.

Najlepšie celkové výsledky boli dosiahnuté pri hodnote *threshold_list* = **0,025**, pri ktorej model dosiahol Accuracy 93,84 %, Precision 87,78 %, Recall 98,99 % a F1-skóre 93,05 %. Táto konfigurácia poskytla najlepší kompromis medzi schopnosťou správne identifikovať anomálne EKG cykly a zároveň minimalizovať počet normálnych vzoriek nesprávne označených ako anomálie.


Pri hodnote *threshold_list* = **0** bola dosiahnutá najvyššia hodnota Precision (90,09 %), avšak Recall dosiahol 94,61 %. Zvýšenie hodnoty prahu na 0,025 viedlo k výraznému nárastu Recall na 98,99 %, pričom pokles Precision bol relatívne malý. Pri

d'alšom zvýšení prahu na hodnotu 0,05 sa Recall zvýšil až na 99,68 %, avšak výraznejšie klesla Precision a F1-skóre v dôsledku rastúceho počtu falošne pozitívnych klasifikácií.



Obrázok 31 – Matica zámen metódy Isolation Forest pre dataset ECG5000 pri hodnote threshold_list = 0

Matica zámen potvrdzuje vysokú schopnosť modelu rozlišovať medzi normálnymi a anomálnymi EKG cyklami. Model správne identifikoval 1772 anomálnych vzoriek a 2432 normálnych vzoriek. Nesprávne bolo klasifikovaných iba 101 anomálnych vzoriek a 195 normálnych vzoriek. Výsledky zodpovedajú hodnote Recall približne 94,6 %, čo znamená, že model dokázal zachytiť väčšinu anomálnych EKG cyklov.



Obrázok 32 – Histogram hodnôt rozhodovacej funkcie metódy Isolation Forest pre dataset ECG5000 pri hodnote threshold_list = 0

Histogram rozhodovacích skóre ukazuje veľmi dobré oddelenie normálnych a anomálnych EKG cyklov. Anomálne vzorky sa koncentrujú prevažne v oblasti záporných hodnôt rozhodovacej funkcie, najčastejšie približne medzi $-0,10$ a $0,01$. Naopak normálne vzorky dosahujú prevažne kladné hodnoty skóre a vytvárajú samostatné rozdelenie v pravej časti histogramu. Medzi oboma skupinami sa nachádza iba malé prekrytie v okolí hodnoty threshold_list = 0, čo vysvetľuje nízky počet nesprávnych klasifikácií pozorovaných v matici zámen.

Na základe dosiahnutých výsledkov možno konštatovať, že metóda Isolation Forest dosiahla na datasete ECG5000 veľmi dobré výsledky. Vďaka výraznému rozdielu medzi normálnymi a anomálnymi EKG cyklami dokázal model vytvoriť spoľahlivú hranicu normálneho správania. Najvhodnejšou hodnotou rozhodovacieho prahu bola threshold_list = **0,025**, ktorá poskytla najvyššie F1-skóre a najvyváženejší pomer medzi metrikami Precision a Recall.

Výsledky metódy Isolation Forest na datasete NAB


Tabuľka 3 – Výsledky metódy Isolation Forest na datasete NAB

Podiel dát	<i>Threshold</i>	Accuracy %	Precision %	Recall %	F1-score %
0.80	0.0	92.01	61.03	100.0	75.8
	-0.1	98.57	89.72	100.0	94.58
	-0.15	99.29	96.68	97.71	97.19
	-0.2	98.37	99.8	87.13	93.03

Tabuľka 3 prezentuje výsledky metódy Isolation Forest na datasete NAB. Hodnoty metrík sú uvedené pre štyri rôzne hodnoty rozhodovacieho prahu (*threshold*) 0, -0,1, -0,15 a -0,2 pri rozdelení dát *train_fraction* = 0,80.


Najlepšie celkové výsledky boli dosiahnuté pri hodnote *threshold_list* = **-0,15**, kde model dosiahol Accuracy 99,29 %, Precision 96,68 %, Recall 97,71 % a F1-skóre 97,19 %. Táto konfigurácia poskytla najlepší kompromis medzi schopnosťou správne identifikovať anomálne stavy zariadenia a zároveň minimalizovať počet normálnych vzoriek nesprávne označených ako anomálie.

Pri hodnote *threshold_list* = **0** model dosiahol maximálnu hodnotu Recall (100 %), čo znamená, že zachytil všetky anomálie prítomné v testovacej množine. Súčasne však bola hodnota Precision výrazne nižšia (61,03 %), keďže model označil ako anomálne aj väčší počet normálnych vzoriek. Postupným znižovaním hodnoty *threshold* sa počet falošne pozitívnych klasifikácií znižoval, čo viedlo k výraznému nárastu Precision a F1-skóre. Pri hodnote *threshold_list* = **-0,2** síce Precision dosiahla takmer 100 %, avšak Recall poklesol na 87,13 %, pretože časť skutočných anomálií zostala nerozpoznaná.



Obrázok 33 – Matica zámen metódy Isolation Forest pre dataset NAB pri hodnote $\text{threshold_list} = -0,15$ a $\text{train_fraction} = 0,80$

Matica zámen potvrdzuje veľmi vysokú úspešnosť modelu pri rozlišovaní medzi normálnym a anomálnym správaním zariadenia. Model správne klasifikoval 3944 normálnych vzoriek a 554 anomálnych vzoriek. Nesprávne bolo klasifikovaných iba 19 normálnych vzoriek a 13 anomálnych vzoriek. Nízky počet falošne pozitívnych aj falošne negatívnych klasifikácií vysvetľuje vysoké hodnoty metrík Precision, Recall a F1-skóre.



Obrázok 34 – Histogram hodnôt rozhodovacej funkcie metódy Isolation Forest pre dataset NAB pri hodnote $\text{threshold_list} = -0,15$ a $\text{train_fraction} = 0,80$

Histogram rozhodovacích skóre ukazuje veľmi výrazné oddelenie normálnych a anomálnych vzoriek. Normálne vzorky sa nachádzajú prevažne v oblasti hodnôt od približne 0,0 do 0,13, zatiaľ čo anomálne vzorky sú sústredené najmä v oblasti okolo -0,22. Medzi oboma skupinami existuje len minimálne prekrytie, čo vysvetľuje veľmi nízky počet chýb klasifikácie pozorovaných v matici zámen. Vertikálna čiara predstavujúca hodnotu `threshold_list = -0,15` sa nachádza medzi oboma rozdeleniami a umožňuje spoľahlivé oddelenie normálnych a anomálnych stavov zariadenia.

Na základe dosiahnutých výsledkov možno konštatovať, že metóda Isolation Forest dosiahla na datasete NAB najlepšie výsledky spomedzi testovaných datasetov. Model dokázal veľmi presne vytvoriť model normálneho správania zariadenia a následne identifikovať odchýlky od tohto správania. Hodnota `threshold_list = -0,15` poskytla najlepší kompromis medzi citlivosťou detekcie anomálií a počtom falošných poplachov, pričom model dosiahol F1-skóre 97,19 %.

4.3.2 Výsledky pre One-Class SVM

Tabuľky č. 4–6 prezentujú výsledky detekcie anomálií pomocou algoritmu One-Class SVM na datasetoch NASA Battery, NAB a ECG5000. V ľavej časti tabuliek sú uvedené testované konfigurácie modelu a použité hodnoty rozhodovacieho prahu (*threshold*), zatiaľ čo pravá časť obsahuje výsledné hodnoty metrík Accuracy, Precision, Recall a F1-skóre.

Počas úvodných experimentov boli testované rôzne hodnoty parametrov `nu` a `gamma`. Na základe dosiahnutých výsledkov bola pre ďalšie experimenty zvolená konfigurácia `kernel = "rbf"`, `nu = 0,05` a `gamma = "auto"`, ktorá poskytovala najlepší kompromis medzi schopnosťou detegovať anomálie a stabilitou výsledkov na analyzovaných datasetoch. V rámci finálnych experimentov bol následne analyzovaný aj vplyv rôznych hodnôt rozhodovacieho prahu (*threshold*) na výslednú klasifikáciu.

V nasledujúcich podkapitolách sú podrobne rozobraté výsledky dosiahnuté na jednotlivých datasetoch.

V tabuľkách sú zelenou farbou označené najlepšie dosiahnuté výsledky v rámci príslušného datasetu.

Výsledky metódy One-Class SVM na datasete NASA Battery

Tabuľka 4 – Výsledky metódy One-Class SVM na datasete NASA Battery


Podiel dát	<i>Threshold</i>	Accuracy %	Precision %	Recall %	F1-score %
0.70	0.0	80.92	89.2	59.5	71.39
	10.0	81.46	80.35	71.09	75.43
	20.0	75.22	64.13	86.48	73.64
0.80	0.0	77.78	92.41	60.53	73.15
	10.0	80.1	87.43	70.36	77.96
	20.0	78.65	76.72	82.5	79.48
0.90	0.0	72.45	95.75	61.4	74.82
	10.0	76.62	93.26	70.03	79.98
	20.0	78.86	87.85	79.42	83.39

Tabuľka 4 prezentuje výsledky metódy One-Class SVM na datasete NASA Battery. Uvedené hodnoty predstavujú priemerné výsledky získané z piatich nezávislých behov realizovaných s rôznymi hodnotami parametra random seed. Počas experimentov boli testované rôzne hodnoty parametra train_fraction a rozhodovacieho prahu (threshold).

Pri konfigurácii train_cycle_fraction = **0,90** boli dosiahnuté najlepšie priemerné výsledky. Vyšší podiel normálnych cyklov v trénovacej množine umožnil modelu vytvoriť presnejšiu reprezentáciu normálneho správania batérie.

Počas experimentov boli testované hodnoty rozhodovacieho prahu **0, 10 a 20**. Najlepšie výsledky boli dosiahnuté pri hodnote threshold_list = 20, kde model dosiahol Accuracy 78,86 %, Precision 87,85 %, Recall 79,42 % a F1-skóre 83,39 %.


Zvyšovanie hodnoty threshold viedlo k nárastu metriky Recall, pretože model označoval za anomálne väčší počet vzoriek a dokázal zachytiť viac skutočných anomálií. Súčasne však dochádzalo k poklesu metriky Precision v dôsledku vyššieho počtu falošne pozitívnych klasifikácií. Hodnota threshold_list = **20** poskytla najlepší kompromis medzi schopnosťou detegovať anomálie a počtom nesprávne označených normálnych vzoriek.



Obrázok 35 – Matica zámen metódy One-Class SVM pre dataset NASA Battery pri hodnote threshold_list = 20 a train_cycle_fraction = 0,90

Z približne 5000 normálnych testovacích vzoriek model správne klasifikoval približne 3887 vzoriek, zatiaľ čo približne 1113 normálnych vzoriek bolo nesprávne označených ako anomálne. Z 10 000 anomálnych vzoriek model správne identifikoval približne 7942 anomálií a približne 2058 anomálií zostalo nerozpoznaných.

Výsledok zodpovedá hodnote Recall približne 79 %, čo znamená, že model dokázal zachytiť väčšinu anomálnych cyklov, avšak časť degradovaných batérií zostala klasifikovaná ako normálna.



Obrázok 36 – Histogram hodnôt rozhodovacej funkcie metódy One-Class SVM pre dataset NASA Battery pri hodnote threshold_list = 20 a train_cycle_fraction = 0,90

Z histogramu je možné pozorovať, že normálne vzorky sa nachádzajú prevažne v pravej časti grafu, zatiaľ čo anomálne vzorky vykazujú výrazne širšie rozdelenie a často dosahujú veľmi nízke hodnoty skóre. Ľavá časť histogramu zodpovedá výrazne degradovaným cyklom batérie. Súčasne je možné pozorovať prekrytie oboch rozdelení, čo naznačuje existenciu anomálnych cyklov, ktoré sa z pohľadu použitých vstupných príznakov podobajú normálnym cyklom.

Ako bolo uvedené pri analýze datasetu NASA Battery v predchádzajúcej časti, niektoré degradované cykly vykazovali veľmi podobné hodnoty sledovaných príznakov ako normálne cykly, čo sťažovalo ich jednoznačnú identifikáciu aj pomocou metódy One-Class SVM.

Výsledky metódy One-Class SVM na datasete ECG5000


Tabuľka 5 – Výsledky metódy One-Class SVM na datasete ECG5000 pri rôznych hodnotách rozhodovacieho prahu

Threshold	Accuracy %	Precision %	Recall %	F1-score %
0.0	91.53	83.21	99.79	90.75
-0.3	96.87	94.59	98.08	96.3
-0.5	92.64	96.78	85.16	90.6

Z výsledkov metódy One-Class SVM na datasete ECG5000 vyplýva, že najlepší celkový výkon bol dosiahnutý pri hodnote threshold_list = **-0,3**, pri ktorej model dosiahol najvyššie F1-skóre. Táto hodnota predstavuje najlepší kompromis medzi


presnosťou detekcie anomálií a schopnosťou zachytiť čo najväčší počet anomálnych EKG cyklov.

Pri hodnote $\text{threshold_list} = 0$ bol dosiahnutý najvyšší Recall, čo znamená, že model zachytil takmer všetky anomálie. Súčasne však bola nižšia Precision, čo naznačuje vyšší počet falošne pozitívnych detekcií. Naopak pri hodnote $\text{threshold_list} = -0,5$ sa zvýšila Precision, ale Recall klesol, teda model bol prísnejší a časť skutočných anomálií nebola zachytená.



Obrázok 37 – Matica zámen metódy One-Class SVM pre dataset ECG5000 pri hodnote $\text{threshold_list} = -0,3$

Matica zámen potvrdzuje vysokú schopnosť modelu rozlišovať medzi normálnymi a anomálnymi EKG cyklami. Model správne identifikoval 1837 anomálnych vzoriek a 2522 normálnych vzoriek. Nesprávne bolo klasifikovaných iba 36 anomálnych vzoriek a 105 normálnych vzoriek.



Obrázok 38 – Histogram hodnôt rozhodovacej funkcie metódy One-Class SVM pre dataset ECG5000 pri hodnote threshold_list = -0,3

Histogram rozhodovacích skóre ukazuje, že normálne a anomálne EKG cykly sú pomerne dobre oddelené. Anomálne vzorky sa nachádzajú najmä v ľavej časti grafu s nižšími hodnotami decision score, zatiaľ čo normálne vzorky sú sústredené prevažne v pravej časti grafu. To potvrdzuje, že One-Class SVM dokázal vytvoriť hranicu normálneho správania EKG signálu a odhaliť cykly s odlišným tvarom.

Na základe výsledkov možno konštatovať, že metóda One-Class SVM dosiahla na datasete ECG5000 veľmi dobré výsledky. Najvhodnejšou hodnotou rozhodovacieho prahu bola threshold_list = -0,3, pretože poskytla najvyššie F1-skóre a najvyváženejší pomer medzi precision a recall.


Výsledky metódy One-Class SVM na datasete NAB

Tabuľka 6 – Výsledky metódy One-Class SVM na datasete NAB

Podiel dát	Threshold	Accuracy %	Precision %	Recall %	F1-score %
0.50	0.0	87.79	42.99	67.11	52.41
	-5.0	89.91	49.66	58.38	53.67
0.70	0.0	86.83	58.86	70.02	63.95
	-5.0	87.89	64.07	62.43	63.24
0.80	0.0	96.64	82.27	93.3	87.44
	-5.0	97.59	90.89	89.77	90.33

Na datasete NAB dosiahla metóda One-Class SVM veľmi dobré výsledky pri rozhodovacom prahu `threshold_list = -5`, pričom na trénovanie bolo použitých 80 % časového radu.


Výsledky naznačujú, že model dokázal spoľahlivo identifikovať väčšinu anomálnych stavov zariadenia pri zachovaní nízkeho počtu nesprávnych klasifikácií normálnych vzoriek.



Obrázok 39 – Matica zámen metódy One-Class SVM pre dataset NAB pri hodnote `threshold_list = -5` a `train_fraction = 0,80`

Matica zámen potvrdzuje vysokú úspešnosť modelu pri rozlišovaní medzi normálnym a anomálnym správaním zariadenia. Model správne klasifikoval 3912 normálnych vzoriek a 509 anomálnych vzoriek. Nesprávne bolo označených iba 51 normálnych vzoriek a 58 anomálnych vzoriek.

Nízky počet falošne pozitívnych aj falošne negatívnych klasifikácií vysvetľuje vysoké hodnoty metrík Precision a Recall. Model tak dokázal zachytiť väčšinu poruchových stavov bez výrazného počtu falošných poplachov.



Obrázok 40 – Histogram hodnôt rozhodovacej funkcie metódy One-Class SVM pre dataset NAB pri hodnote `threshold_list = -5` a `train_fraction = 0,80`

Histogram rozhodovacích skóre zobrazuje rozdelenie hodnôt rozhodovacej funkcie modelu pre normálne a anomálne vzorky. Normálne vzorky sa sústreďujú prevažne v oblasti kladných hodnôt skóre, zatiaľ čo anomálne vzorky dosahujú výrazne nižšie hodnoty a nachádzajú sa najmä v ľavej časti grafu.

Na základe dosiahnutých výsledkov možno konštatovať, že metóda One-Class SVM bola na datasete NAB schopná efektívne modelovať normálne správanie zariadenia a následne identifikovať odchýlky od tohto správania. Hodnota `threshold_list = -5` poskytla najlepší kompromis medzi citlivosťou detekcie anomálií a počtom falošných poplachov, pričom model dosiahol F1-skóre 90,33 %.

4.3.3 Výsledky pre Autoencoder

Tabuľky č. 7–9 prezentujú výsledky detekcie anomálií pomocou metódy Autoencoder na datasetoch NASA Battery, NAB a ECG5000. V ľavej časti tabuliek sú uvedené použité konfigurácie modelu a hodnoty rozhodovacieho prahu (`threshold`), zatiaľ čo pravá časť obsahuje hodnotenie modelu pomocou metrík Accuracy, Precision, Recall a F1-skóre.

Počas úvodných experimentov boli testované rôzne konfigurácie architektúry Autoencoderu, najmä počet neurónov v skrytých vrstvách, veľkosť latentnej reprezentácie, veľkosť dávky a parametre učenia. Na základe dosiahnutých výsledkov

bola pre finálne experimenty zvolená konfigurácia $hidden_dim = 32$, $encoding_dim = 8$, $batch_size = 64$, $learning_rate = 0,001$, $epochs = 100$, $patience = 10$ a $validation_split = 0,2$.

Pri finálnych experimentoch bola rekonštrukčná chyba použitá ako skóre anomálie a výsledná klasifikácia závisela od zvoleného rozhodovacieho prahu. V rámci experimentov boli analyzované rôzne hodnoty $threshold$ s cieľom posúdiť ich vplyv na výsledné metriky modelu.

Pri datasete NASA Battery boli výsledky získané ako priemer z piatich nezávislých behov realizovaných s rôznymi hodnotami parametra $random\ seed$. Pri datasete NAB bolo použité rovnaké rozdelenie dát ako pri ostatných metódach. Pri datasete ECG5000 bol využitý pôvodný preddefinovaný split TRAIN/TEST poskytnutý autorom datasetu.

V tabuľkách sú zelenou farbou označené najlepšie dosiahnuté výsledky v rámci príslušného datasetu.

Výsledky metódy Autoencoder na datasete NASA Battery

Tabuľka 7 – Výsledky metódy Autoencoder na datasete NASA Battery


Podiel dát	<i>Threshold</i>	Accuracy %	Precision %	Recall %	F1-score %
0.80	0.0	50.0	50.0	100.0	66.67
	0.002	76.82	74.01	84.53	78.03
	0.005	75.77	86.08	63.31	71.81
0.90	0.0	66.67	66.67	100.0	80.0
	0.002	86.91	86.63	95.75	90.84
	0.005	76.55	90.54	72.77	80.43

Tab. 7 prezentuje výsledky detekcie anomálií pomocou metódy Autoencoder na datasete NASA Battery. Uvedené hodnoty predstavujú priemerné výsledky získané z piatich nezávislých behov realizovaných pri rozdelení dát $train_cycle_fraction = 0,90$.

Najlepšie priemerné výsledky boli dosiahnuté pri hodnote rozhodovacieho prahu **0,002**. Model dosiahol hodnoty Accuracy 86,91 %, Precision 86,63 %, Recall 95,75 % a F1-skóre 90,84 %. Spomedzi všetkých testovaných konfigurácií predstavuje táto kombinácia najlepší kompromis medzi schopnosťou detegovať anomálie a počtom nesprávne klasifikovaných normálnych vzoriek.


Vysoká hodnota metriky Recall (95,75 %) naznačuje, že model dokázal správne identifikovať takmer všetky anomálne cykly batérií. Z celkového počtu približne 10 000 anomálnych vzoriek bolo správne rozpoznávaných v priemere 9575 vzoriek, pričom iba približne 425 anomálií zostalo neodhalených. Táto vlastnosť je mimoriadne dôležitá v

oblasti technickej diagnostiky, kde je prioritou minimalizovať počet neodhalených porúch.



Obrázok 41 – Matica zámien metódy Autoencoder pre dataset NASA Battery pri hodnote threshold_list = 0,002 a train_cycle_fraction = 0,90

Priemerná matica zámien ukazuje, že model správne klasifikoval približne 3462 normálnych vzoriek a 9575 anomálnych vzoriek. Na druhej strane bolo približne 1538 normálnych vzoriek nesprávne označených ako anomálie a približne 425 anomálnych vzoriek bolo klasifikovaných ako normálne. Vyšší počet falošne pozitívnych klasifikácií je dôsledkom nastavenia rozhodovacieho prahu, ktoré bolo optimalizované s cieľom maximalizovať schopnosť zachytiť degradované cykly batérie.



Obrázok 42 – Histogram hodnôt rozhodovacej funkcie metódy Autoencoder pre dataset NASA Battery pri hodnote threshold_list = 0,002, train_cycle_fraction = 0,90 a seeds = 43

Histogram rekonštrukčnej chyby poskytuje detailnejší pohľad na správanie modelu. Normálne vzorky sa koncentrujú v oblasti nízkych hodnôt rekonštrukčnej chyby, zatiaľ čo anomálne vzorky dosahujú výrazne vyššie hodnoty. Rozdelenia oboch tried sú vo veľkej miere oddelené, čo vysvetľuje vysokú úspešnosť modelu.

Zvislá čiara na histograme predstavuje rozhodovací prah **0,002**. Vzorky s rekonštrukčnou chybou vyššou ako táto hodnota boli označené ako anomálie, zatiaľ čo vzorky s nižšou chybou boli klasifikované ako normálne. Z grafu je možné pozorovať, že väčšina normálnych vzoriek sa nachádza naľavo od prahu, zatiaľ čo dominantná časť anomálnych vzoriek sa nachádza napravo od neho.

Pri detailnej analýze jednotlivých behov bol najlepší výsledok dosiahnutý pri hodnote seeds = **43**. Histogram rekonštrukčných chýb z tohto behu vykazoval najvýraznejšie oddelenie normálnych a anomálnych vzoriek. Táto skutočnosť naznačuje, že rozdelenie dát vytvorené pomocou parametra seeds = **43** poskytlo modelu najreprezentatívnejšiu tréningovú množinu normálnych cyklov.

Dosiahnuté výsledky naznačujú, že Autoencoder dokáže efektívne zachytiť komplexné vzťahy medzi jednotlivými príznakmi a využiť ich pri identifikácii anomálnych cyklov. Táto schopnosť mohla prispieť k dosiahnutiu najvyšších hodnôt Recall a F1-skóre spomedzi všetkých testovaných metód na datasete NASA Battery. Z pohľadu detekcie poruchových stavov ide o veľmi priaznivý výsledok, keďže model dokázal zachytiť väčšinu degradovaných batériových cyklov pri zachovaní vysokej presnosti klasifikácie.

Výsledky metódy Autoencoder na datasete ECG5000


Tabuľka 8 – Výsledky metódy Autoencoder na datasete ECG5000 pri rôznych hodnotách rozhodovacieho prahu

<i>Threshold</i>	Accuracy %	Precision %	Recall %	F1-score %
0.0	41.62	41.62	100.0	58.78
0.7	94.53	94.43	92.31	93.36
1.0	82.16	94.96	60.33	73.78

Tab. 8 prezentuje výsledky detekcie anomálií pomocou metódy Autoencoder na datasete ECG5000. Model bol trénovaný výlučne na normálnych EKG signáloch (trieda 1), pričom všetky ostatné triedy boli považované za anomálie a boli použité iba počas testovania. Na experiment bol využitý pôvodný TRAIN/TEST split poskytnutý autorom datasetu.


Najlepšie výsledky boli dosiahnuté pri hodnote rozhodovacieho prahu threshold_list = 0,7. Model dosiahol Accuracy 94,53 %, Precision 94,43 %, Recall 92,31

% a F1-skóre 93,36 %. Dosiahnuté hodnoty naznačujú veľmi dobrú schopnosť modelu rozlišovať medzi normálnymi a anomálnymi EKG signálmi.



Obrázok 43 – Matica zámen metódy Autoencoder pre dataset ECG5000 pri hodnote `threshold_list = 0,7`


Matica zámen ukazuje, že model správne identifikoval 2525 normálnych vzoriek a 1729 anomálnych vzoriek. Nesprávne bolo klasifikovaných iba 102 normálnych vzoriek a 144 anomálnych vzoriek. Relatívne nízky počet chýb klasifikácie potvrdzuje, že rekonštrukčná chyba predstavuje vhodný ukazovateľ na odlíšenie normálneho a anomálneho správania v EKG signáloch.



Obrázok 44 – Histogram hodnôt rozhodovacej funkcie metódy Autoencoder pre dataset ECG5000 pri hodnote threshold_list = 0,7

Histogram rekonštrukčných chýb ukazuje výrazné oddelenie oboch tried. Normálne vzorky dosahujú prevažne nízke hodnoty rekonštrukčnej chyby sústredené v blízkosti nuly, zatiaľ čo anomálne vzorky vykazujú podstatne vyššie hodnoty chyby. Rozdelenia sa prekrývajú iba v malej oblasti okolo rozhodovacieho prahu, čo vysvetľuje vysoké hodnoty všetkých hodnotiacich metrík.

Zvislá čiara na histograme predstavuje hodnotu threshold_list = **0,7**, ktorá určuje hranicu medzi normálnymi a anomálnymi vzorkami. Vzorky s rekonštrukčnou chybou vyššou ako táto hodnota boli klasifikované ako anomálie, zatiaľ čo vzorky s nižšou chybou boli označené ako normálne.



Obrázok 45 – Rekonštrukcie EKG signálov pomocou metódy Autoencoder pri hodnote $\text{threshold_list} = 0,7$

Na obrázku rekonštrukcie signálov je možné pozorovať rozdiel v správaní modelu pri normálnych a anomálnych vzorkách. Pri normálnom EKG signále rekonštruovaný priebeh veľmi presne kopíruje pôvodný vstupný signál. Rozdiel medzi vstupom a rekonštrukciou je minimálny, čo vedie k nízkej rekonštrukčnej chybe a správnej klasifikácii vzorky ako normálnej.

Pri anomálnom EKG signále je situácia odlišná. Autoencoder bol počas tréningu vystavený iba normálnym vzorkám, a preto sa naučil efektívne rekonštruovať iba normálny priebeh srdcovej aktivity. V prípade anomálneho signálu už rekonštrukcia nedokáže presne zachytiť všetky charakteristické zmeny tvaru signálu. Rozdiel medzi vstupným a rekonštruovaným priebehom je výrazne väčší, čo vedie k zvýšeniu rekonštrukčnej chyby a následnej klasifikácii vzorky ako anomálnej.

Dosiahnuté výsledky potvrdzujú, že Autoencoder je veľmi vhodný na detekciu anomálií v EKG signáloch. Vzhľadom na výrazné rozdiely medzi normálnymi a patologickými priebehmi dokáže model vytvoriť presnú reprezentáciu normálneho srdcového rytmu a následne spoľahlivo identifikovať odchýlky od tohto správania. Najvyššia hodnota F1-skóre spomedzi testovaných metód na datase ECG5000 naznačuje, že Autoencoder poskytuje veľmi dobrý kompromis medzi presnosťou detekcie a schopnosťou zachytiť anomálne vzorky.


Výsledky metódy Autoencoder na datasete NAB

Tabuľka 9 – Výsledky metódy Autoencoder na datasete NAB

Podiel dát	Threshold	Accuracy %	Precision %	Recall %	F1-score %
0.70	0.0	16.69	16.69	100.0	28.61
	0.00006	83.19	49.61	44.71	47.03
	0.0001	85.05	59.05	33.95	43.11
0.80	0.0	12.52	12.52	100.0	22.25
	0.00006	95.85	80.22	88.71	84.25
	0.0001	94.64	83.75	70.9	76.79


Tab. 9 prezentuje výsledky detekcie anomálií pomocou metódy Autoencoder na datasete NAB. Na zabezpečenie porovnateľnosti s ostatnými metódami boli experimenty realizované pri rôznych hodnotách parametra `train_fraction`, pričom najlepšie výsledky boli dosiahnuté pri rozdelení dát `train_fraction = 0,80`.

Najlepšia konfigurácia dosiahla hodnoty Accuracy 95,85 %, Precision 80,22 %, Recall 88,71 % a F1-skóre 84,25 % pri rozhodovacom prahu `threshold_list = 0,00006`. Výsledky potvrdzujú, že Autoencoder dokáže efektívne identifikovať väčšinu anomálnych udalostí aj v prípade časových radov obsahujúcich prirodzenú variabilitu meraných hodnôt.



Obrázok 46 – Histogram hodnôt rozhodovacej funkcie metódy Autoencoder pre dataset NAB pri hodnote `threshold_list = 0.00006` a `train_fraction = 0,80`

Matica zámen ukazuje, že model správne klasifikoval 3839 normálnych vzoriek a 503 anomálnych vzoriek. Nesprávne bolo označených 124 normálnych vzoriek a 64 anomálnych vzoriek. Relatívne nízky počet chýb klasifikácie viedol k vysokej hodnote Accuracy presahujúcej 95 %, čo naznačuje dobrú schopnosť modelu rozlišovať medzi normálnym a anomálnym správaním systému.



Obrázok 47 – Histogram hodnôt rozhodovacej funkcie metódy Autoencoder pre dataset NAB pri hodnote threshold_list = 0,00006 a train_fraction = 0,80

Histogram rekonštrukčných chýb zobrazený v logaritmickej mierke poskytuje detailnejší pohľad na rozdelenie oboch tried. Väčšina normálnych vzoriek dosahuje veľmi nízke hodnoty rekonštrukčnej chyby, ktoré sa koncentrujú približne v intervale od 10^{-6} do 10^{-4} . Anomálne vzorky sa nachádzajú prevažne pri vyšších hodnotách rekonštrukčnej chyby, najčastejšie v oblasti od 10^{-5} do 10^{-3} .

Na rozdiel od datasetu ECG5000 však možno pozorovať čiastočné prekrytie oboch rozdelení v okolí rozhodovacieho prahu. To znamená, že niektoré anomálne úseky časového radu vykazujú podobné charakteristiky ako normálna prevádzka zariadenia, zatiaľ čo niektoré normálne vzorky sa svojím správaním približujú anomálnym udalostiam. Práve toto prekrytie vysvetľuje nižšiu hodnotu Precision v porovnaní s ostatnými metrikami.

Zvislá čiara na histograme predstavuje rozhodovací prah 0,00006. Vzorky s vyššou rekonštrukčnou chybou boli klasifikované ako anomálie, zatiaľ čo vzorky s nižšou chybou boli označené ako normálne. Zvolená hodnota prahu predstavuje kompromis medzi schopnosťou zachytiť čo najväčší počet anomálií a súčasným obmedzením počtu falošne pozitívnych klasifikácií.

Dosiahnutá hodnota Recall 88,71 % naznačuje, že model úspešne identifikoval väčšinu skutočných anomálií. Súčasne hodnota Precision 80,22 % ukazuje, že časť vzoriek označených ako anomálie bola v skutočnosti normálna. Takéto správanie je pri

reálnych časových radoch očakávané, pretože hranica medzi normálnym a anomálnym stavom nemusí byť vždy jednoznačne definovaná.

Výsledky potvrdzujú, že Autoencoder predstavuje vhodný nástroj na detekciu anomálií v časových radoch datasetu NAB. Model dokázal vytvoriť reprezentáciu normálneho správania systému a následne identifikovať odchýlky pomocou rekonštrukčnej chyby. Napriek čiastočnému prekrytiu rozdelení normálnych a anomálnych vzoriek dosiahol model vysokú úspešnosť detekcie a poskytol výsledky porovnateľné s ostatnými testovanými metódami.

Súhrn optimálnych nastavení:

V nasledujúcej tabuľke sú uvedené najlepšie konfigurácie jednotlivých metód detekcie anomálií dosiahnuté na analyzovaných datasetoch. Tabuľka sumarizuje hodnoty rozhodovacieho prahu (threshold) a podielu trénovacích dát (train fraction), pri ktorých boli dosiahnuté najlepšie výsledky v rámci jednotlivých experimentov.

Tabuľka 10 – Najlepšie konfigurácie a dosiahnuté výsledky jednotlivých metód

Metóda	Dataset	Najlepšia konfigurácia		Metriky [%]			
		Threshold	Train fraction	Acc.	Prec.	Rec.	F1
iForest	NASA Battery	0.065	0.90	85.28	85.58	94.09	89.54
	ECG5000	0.0	–	93.42	90.09	94.61	92.29
	NAB	-0.15	0.80	99.29	96.68	97.71	97.19
OCSVM	NASA Battery	20.0	0.90	78.86	87.85	79.42	83.39
	ECG5000	-0.3	–	96.87	94.59	98.08	96.3
	NAB	-5.0	0.80	97.59	90.89	89.77	90.33
AE	NASA Battery	0.002	0.90	86.91	86.63	95.75	90.84
	ECG5000	0.7	–	94.53	94.43	92.31	93.36
	NAB	0.00006	0.80	95.85	80.22	88.71	84.25

4.4 Porovnanie výsledkov

Na základe vykonaných experimentov bolo možné porovnať správanie troch vybraných metód detekcie anomálií – Isolation Forest, One-Class SVM a Autoencoder – na troch datasetoch reprezentujúcich rozdielne typy dát. Dataset NAB predstavoval priemyselné časové rady, ECG5000 obsahoval biomedicínske signály EKG a NASA Battery reprezentoval multivariačné degradačné dáta lítium-iónových batérií.

Výsledky ukázali, že úspešnosť jednotlivých metód závisí nielen od zvoleného algoritmu, ale aj od charakteru analyzovaných dát. Najlepšie výsledky boli vo všeobecnosti dosiahnuté na datasete ECG5000, kde boli anomálie reprezentované výraznými zmenami tvaru EKG signálu. V tomto prípade všetky tri metódy dosahovali vysoké hodnoty metrík, pričom najlepšie výsledky boli dosiahnuté metódou One-Class SVM.

Na datasete NAB boli rozdiely medzi metódami výraznejšie. One-Class SVM dosiahol najlepšie výsledky pri vhodne zvolenom rozhodovacom prahu, pričom dosahoval vysoké hodnoty Precision aj Recall. Autoencoder taktiež vykazoval veľmi dobré výsledky a bol schopný zachytiť krátkodobé aj dlhodobé odchýlky v správaní časového radu. Isolation Forest dosahoval mierne nižšiu úspešnosť, avšak poskytoval stabilné výsledky aj bez náročného ladenia parametrov.

Najnáročnejším datasetom bol NASA Battery. V tomto prípade boli anomálie definované na základe poklesu kapacity batérie, pričom rozdiely v použitých vstupných príznakoch neboli vždy jednoznačné. Časť degradovaných cyklov mala podobné hodnoty napätia, prúdu a teploty ako normálne cykly, čo sťažovalo ich rozlíšenie. Napriek tomu všetky tri metódy dokázali identifikovať významnú časť anomálnych vzoriek. Najlepšie výsledky dosiahol Autoencoder, ktorý dokázal zachytiť aj zložitejšie vzťahy medzi jednotlivými príznakmi. One-Class SVM poskytol vyvážený kompromis medzi presnosťou a citlivosťou, zatiaľ čo Isolation Forest preukázal robustnosť a jednoduchú aplikovateľnosť.

Z celkového porovnania vyplýva, že neexistuje univerzálne najlepšia metóda pre všetky typy dát. Autoencoder dosahoval veľmi dobré výsledky najmä pri komplexných dátach s väčším počtom vzájomne prepojených príznakov. One-Class SVM poskytoval veľmi dobré výsledky pri správnom nastavení parametrov a rozhodovacieho prahu. Isolation Forest síce vo viacerých prípadoch dosahoval o niečo nižšie hodnoty metrík, avšak jeho výhodou bola jednoduchá implementácia, nízka výpočtová náročnosť a stabilné správanie naprieč rôznymi datasetmi.

4.5 Diskusia o vhodnosti metód pre priemyselné prostredie

Priemyselné diagnostické systémy sa často stretávajú s nedostatkom poruchových dát, pretože poruchové stavy vznikajú relatívne zriedkavo a ich získanie môže byť finančne alebo technicky náročné. Z tohto dôvodu boli v práci skúmané metódy, ktoré sa dokážu učiť prevažne z normálnych prevádzkových dát a následne identifikovať odchýlky od bežného správania systému.

Výsledky experimentov potvrdili, že všetky tri analyzované metódy sú vhodné pre scenáre, v ktorých je dostupné veľké množstvo normálnych dát a iba obmedzené množstvo anomálnych vzoriek. Jednotlivé prístupy sa však líšia nárokmi na implementáciu, nastavovanie parametrov a výpočtové zdroje.

Isolation Forest predstavuje praktické riešenie pre aplikácie, kde je dôležitá jednoduchosť implementácie a nízka výpočtová náročnosť. Výhodou tejto metódy je rýchle nasadenie a schopnosť spracovávať aj rozsiahle datasety bez potreby zložitého ladenia parametrov.

One-Class SVM poskytuje veľmi dobré výsledky pri správnom nastavení parametrov a rozhodovacieho prahu. Umožňuje efektívne vytvoriť hranicu normálneho správania systému, avšak jeho úspešnosť je vo väčšej miere závislá od kvality nastavenia modelu a charakteru vstupných dát.

Autoencoder sa ukázal ako vhodný najmä pri komplexnejších dátach, kde je potrebné zachytiť vzťahy medzi viacerými príznakmi súčasne. Vďaka schopnosti vytvárať vnútornú reprezentáciu normálneho správania dokáže identifikovať aj menej výrazné odchýlky, ktoré nemusia byť jednoducho rozpoznateľné klasickými metódami. Nevýhodou sú vyššie nároky na výpočtový výkon a dlhší čas potrebný na tréning modelu.

Z pohľadu praktického nasadenia neexistuje univerzálne riešenie vhodné pre všetky typy úloh. Výber konkrétnej metódy by mal vychádzať z charakteru monitorovaného systému, množstva dostupných dát, požadovanej presnosti detekcie a dostupných výpočtových zdrojov.

Na základe dosiahnutých výsledkov možno konštatovať, že metódy detekcie anomálií založené na učení z normálnych dát predstavujú perspektívny nástroj pre moderné systémy prediktívnej údržby a diagnostiky technických zariadení. Ich využitie umožňuje identifikovať potenciálne poruchové stavy ešte pred vznikom závažného zlyhania zariadenia, čím prispieva k zvýšeniu spoľahlivosti, bezpečnosti a efektívnosti prevádzky.

5 Vyhodnotenie a zhodnotenie dosiahnutých výsledkov

5.1 Splnenie cieľov práce

Hlavným cieľom bakalárskej práce bolo analyzovať možnosti detekcie anomálií v situáciách, keď je k dispozícii obmedzené množstvo anomálnych dát, a porovnať vlastnosti vybraných metód na rôznych typoch datasetov.

Na splnenie tohto cieľa boli implementované a experimentálne overené tri prístupy detekcie anomálií – Isolation Forest, One-Class SVM a Autoencoder. Metódy boli testované na troch datasetoch reprezentujúcich rozdielne oblasti použitia, konkrétne priemyselné časové rady, biomedicínske signály EKG a degradačné dáta lítium-iónových batérií.

Súčasťou práce bolo prieskumovanie dát, návrh experimentálnej metodiky, výber vhodných parametrov modelov a následné vyhodnotenie dosiahnutých výsledkov pomocou metrík Accuracy, Precision, Recall a F1-skóre. Všetky modely boli trénované výlučne na normálnych dátach, čo zodpovedá podmienkam reálnych diagnostických systémov, kde sú poruchové stavy zriedkavé alebo nie sú počas tréningu dostupné.

Výsledky experimentov potvrdili, že všetky skúmané metódy sú schopné identifikovať anomálne správanie aj bez využitia anomálnych vzoriek počas tréningu. Zároveň sa ukázalo, že kvalita detekcie závisí od charakteru analyzovaných dát a od vhodného nastavenia parametrov modelu. Najlepšie výsledky boli dosiahnuté pri datasete ECG5000, zatiaľ čo dataset NASA Battery predstavoval najnáročnejšiu úlohu vzhľadom na vysokú podobnosť medzi normálnymi a degradovanými cyklami.

Na základe vykonaných experimentov možno konštatovať, že stanovené ciele práce boli splnené. Práca preukázala, že metódy detekcie anomálií založené na učení z normálnych dát predstavujú perspektívny nástroj pre monitorovanie technických systémov a môžu byť úspešne využité v úlohách prediktívnej údržby a diagnostiky poruchových stavov.

5.2 Porovnanie s inými prístupmi

V oblasti detekcie anomálií existuje veľké množstvo prístupov, ktoré možno rozdeliť na metódy založené na klasifikácii, zhľukovaní, štatistických modeloch alebo neurónových

sieťach. V tejto práci boli zvolené metódy Isolation Forest, One-Class SVM a Autoencoder, pretože umožňujú tréning prevažne alebo úplne na normálnych dátach.

Výhodou algoritmu Isolation Forest je jeho relatívne jednoduchá implementácia, nízka výpočtová náročnosť a schopnosť pracovať aj s rozsiahlejšími datasetmi. Metóda dosahovala stabilné výsledky najmä pri datasete NAB a poskytovala dobrý kompromis medzi presnosťou a rýchlosťou spracovania.

One-Class SVM umožňuje vytvoriť hranicu normálneho správania systému a následne identifikovať odľahlé vzorky. Výsledky ukázali, že metóda je citlivá na nastavenie parametrov a rozhodovacieho prahu, avšak pri vhodnej konfigurácii dosahuje veľmi dobré výsledky. Najlepšie výsledky boli pozorované najmä pri datasete ECG5000.

Autoencoder predstavuje prístup založený na neurónových sieťach, ktorý sa snaží rekonštruovať vstupné dáta. Anomálie sú následne identifikované na základe zvýšenej rekonštrukčnej chyby. Výhodou tejto metódy je schopnosť modelovať zložitejšie nelineárne vzťahy vo vstupných dátach. Nevýhodou je vyššia výpočtová náročnosť a potreba vhodného nastavenia architektúry neurónovej siete.

Výsledky práce naznačujú, že neexistuje univerzálne najlepšia metóda pre všetky typy dát. Úspešnosť jednotlivých prístupov závisí od charakteru dát, od spôsobu reprezentácie anomálií a od kvality dostupných príznakov. Preto je pri praktickom nasadení potrebné zohľadniť konkrétnu aplikačnú oblasť a vlastnosti monitorovaného systému.

5.3 Možnosti budúceho rozšírenia a aplikácie v praxi

Jednou z možností ďalšieho rozšírenia práce je testovanie ďalších metód detekcie anomálií, napríklad Local Outlier Factor, DBSCAN alebo modelov založených na hlbokom učení určených špeciálne pre časové rady. Zaujímavým smerom môže byť aj využitie pokročilejších architektúr autoenkodérov alebo rekurentných neurónových sietí.

Ďalší výskum môže byť zameraný na rozšírenie množiny vstupných príznakov a na automatizovaný výber najvýznamnejších charakteristík. Pri datasete NASA Battery sa ukázalo, že niektoré degradované cykly sú z pohľadu použitých vstupných veličín veľmi podobné normálnym cyklom. Využitie dodatočných príznakov by preto mohlo prispieť k lepšiemu odlíšeniu jednotlivých stavov batérie.

Praktické využitie prezentovaných metód je možné najmä v oblasti prediktívnej údržby priemyselných zariadení, monitorovania technického stavu batériových

systémov, zdravotníckych aplikácií založených na analýze EKG signálov a všeobecne v systémoch, kde je potrebné včas identifikovať neštandardné správanie.

Výsledky práce zároveň potvrdzujú, že metódy učenia na normálnych dátach predstavujú vhodné riešenie pre reálne aplikácie, v ktorých je získanie reprezentatívneho množstva anomálnych dát náročné alebo ekonomicky nevýhodné.

Záver

Bakalárska práca bola zameraná na problematiku detekcie anomálií pri nedostatku anomálnych dát. Hlavným cieľom bolo analyzovať možnosti využitia metód Isolation Forest, One-Class SVM a Autoencoder na rôznych typoch datasetov a porovnať ich vlastnosti z hľadiska úspešnosti detekcie anomálií.

V teoretickej časti boli predstavené základné princípy strojového učenia, problematika detekcie anomálií a charakteristika vybraných algoritmov. Osobitná pozornosť bola venovaná prístupom, ktoré umožňujú tréning modelov prevažne alebo výlučne na normálnych dátach.

Praktická časť práce zahŕňala predspracovanie troch datasetov reprezentujúcich rôzne oblasti použitia – priemyselné časové rady NAB, biomedicínske signály ECG5000 a degradačné dáta NASA Battery. Následne boli implementované a experimentálne vyhodnotené metódy Isolation Forest, One-Class SVM a Autoencoder. Výsledky boli analyzované pomocou metrík Accuracy, Precision, Recall a F1-score.

Experimenty ukázali, že všetky skúmané metódy dokážu úspešne identifikovať anomálne správanie aj v prípade, keď počas tréningu nie sú dostupné anomálne vzorky. Súčasne sa potvrdilo, že výsledná úspešnosť závisí od charakteru dát, kvality vstupných príznakov a nastavenia parametrov modelu. Pri niektorých datasetoch boli anomálie výrazne odlišené od normálnych dát, zatiaľ čo pri iných prípadoch dochádzalo k čiastočnému prekrytiu oboch skupín, čo predstavovalo náročnejšiu úlohu pre všetky testované metódy.

Prínosom práce je systematické porovnanie troch populárnych prístupov detekcie anomálií na rozdielnych typoch dát pri zachovaní jednotnej metodiky experimentov. Získané výsledky potvrdzujú, že metódy založené na učení normálneho správania predstavujú perspektívny nástroj pre riešenie úloh detekcie porúch v situáciách, keď je množstvo dostupných anomálnych dát obmedzené.

Na záver možno konštatovať, že stanovené ciele práce boli splnené a získané poznatky môžu slúžiť ako základ pre ďalší výskum a praktické nasadenie systémov detekcie anomálií v priemyselných, zdravotníckych aj technických aplikáciách.

Literatúra

- [1] HUIMIN LU (ed.). Artificial Intelligence and Robotics. Part of the book series: *Studies in Computational Intelligence (Vol. 917)*. Department of Mechanical and Control Engineering, Kyushu Institute of Technology, Kitakyushu, Japan, 2021. ISBN 978-3-030-56177-2. Dostupné na <https://link.springer.com/book/10.1007/978-3-030-56178-9>
- [2] ANIS KOUBAA, AHMAD TAHER AZAR (eds.). Deep Learning for Unmanned Systems. Part of the book series: *Studies in Computational Intelligence (Vol. 984)*. College of Computer and Information Sciences Prince Sultan University Riyadh, Saudi Arabia, Faculty of Computers and Artificial Intelligence Benha University Benha, Egypt, 2021. ISBN 978-3-030-77938-2. Dostupné na <https://link.springer.com/book/10.1007/978-3-030-77939-9>
- [3] VARUN CHANDOLA, ARINDAM BANERJEE, VIPIN KUMAR. Anomaly detection: A survey. In *ACM Journals/ACM Computing Surveys/Archive (Vol. 41, No. 3)*. Association for Computing Machinery New York NY United States, July 2009. ISSN 0360-0300. Dostupné na <https://dl.acm.org/toc/csur/2009/41/3>
- [4] What Is Anomaly Detection? [online]. IBM. 2023-12-12. Dostupné na <https://www.ibm.com/think/topics/anomaly-detection>
- [5] Predictive Maintenance Machine Learning: A Practical Guide [online]. *Neural Concept*. 2024-05-17. Dostupné na <https://www.neuralconcept.com/post/how-ai-is-used-in-predictive-maintenance>
- [6] ROMAN CHUPRYNA, SERHII LELEKO. Predictive Maintenance with Machine Learning: A Complete Guide [online]. *SPD Technology*. 2025-07-04. Dostupné na <https://spd.tech/machine-learning/predictive-maintenance/>
- [7] CAMILO QUIROZ-VÁZQUEZ. Anomaly detection in machine learning: Finding outliers for optimization of business functions [online]. IBM. 2024-07-25. Dostupné na <https://www.ibm.com/think/topics/machine-learning-for-anomaly-detection>
- [8] CHALAPATHY, R., CHAWLA, S. Deep Learning for Anomaly Detection: A Survey. Part of the arXiv (arXiv:1901.03407). Cornell University. 2019-01-24. Dostupné na <https://arxiv.org/pdf/1901.03407>
- [9] FEI TONY LIU, KAI MING TING, ZHI-HUA ZHOU. Isolation Forest. In *2008 Eighth IEEE International Conference on Data Mining: IEEE*. 2009-02-10. ISBN 978-0-7695-3502-9. Dostupné na <https://ieeexplore.ieee.org/document/4781136>

- [10] BERNHARD SCHÖLKOPF, JOHN C. PLATT, JOHN SHAWE-TAYLOR, ALEX J. SMOLA, ROBERT C. WILLIAMSON. Estimating the Support of a High-Dimensional Distribution. In *Neural Computation (Vol. 13, Issue: 7): MIT Press*. 2001-07-01. ISSN 0899-7667. Dostupné na <https://ieeexplore.ieee.org/document/6790022>
- [11] MARKUS M. BREUNIG, HANS-PETER KRIEGEL, RAYMOND T. NG, JÖRG SANDER. LOF: identifying density-based local outliers. In *ACM SIGMOD Record (Vol. 29, Issue 2), p. 93-104: ACM*. 2000-05-16. ISSN 0163-5808. Dostupné na <https://dl.acm.org/doi/epdf/10.1145/335191.335388>
- [12] LocalOutlierFactor [online]. *Scikit-learn*. 2017-08-17. Dostupné na <https://scikit-learn.org/stable/modules/generated/sklearn.neighbors.LocalOutlierFactor.html>
- [13] Local Outlier Factor [online]. *GeeksForGeeks*. 2025-07-02. Dostupné na <https://www.geeksforgeeks.org/machine-learning/local-outlier-factor/>
- [14] J. MACQUEEN. LUCIEN M. LE CAM, JERZY NEYMAN (eds.). Some methods for classification and analysis of multivariate observations (Vol. 5.1). In *Project euclid: The Regents of the University of California, 1967-01-01*. Dostupné na <https://projecteuclid.org/ebooks/berkeley-symposium-on-mathematical-statistics-and-probability/Proceedings-of-the-Fifth-Berkeley-Symposium-on-Mathematical-Statistics-and/chapter/Some-methods-for-classification-and-analysis-of-multivariate-observations/bsmsp/1200512992?tab=ArticleFirstPage>
- [15] Anomaly detection (K-means) [online]. *EDGE IMPULSE*. 2025-09-10. Dostupné na <https://docs.edgeimpulse.com/studio/projects/learning-blocks/blocks/anomaly-detection-k-means>
- [16] ALLAN PORRAS. Implementing Real-Time Anomaly Detection with K-Means Clustering [online]. *4GEEKS*. 2025-10-19. Dostupné na <https://blog.4geeks.io/implementing-real-time-anomaly-detection-with-k-means-clustering/>
- [17] I.T. JOLLIFFE. Principal Component Analysis, Second Edition. Part of the *Springer Series in Statistics*, 2002. ISBN 0-387-95442-2. Dostupné na [http://cda.psych.uiuc.edu/statistical_learning_course/Jolliffe%20I.%20Principal%20Component%20Analysis%20\(2ed.,%20Springer,%202002\)\(518s\)_MVsa_.pdf](http://cda.psych.uiuc.edu/statistical_learning_course/Jolliffe%20I.%20Principal%20Component%20Analysis%20(2ed.,%20Springer,%202002)(518s)_MVsa_.pdf)

- [18] BADRINARAYAN M. Anomaly Detection Using PCA: Unveiling Insights in Data Anomalies [online]. *Analytics Vidhya*. 2024-04-01. Dostupné na <https://www.analyticsvidhya.com/blog/2024/04/anomaly-detection-using-pca-unveiling-insights-in-data-anomalies/>
- [19] JAMES McCaffrey. Anomaly Detection Using Principal Component Analysis (PCA) [online]. *Visual Studio Magazine*. 2021-10-21. Dostupné na <https://visualstudiomagazine.com/articles/2021/10/20/anomaly-detection-pca.aspx>
- [20] MARTIN ESTER, HANS-PETER KRIEGL, JÖRG SANDER, XIAOWEI XU. A density-based algorithm for discovering clusters in large spatial databases with noise. In *KDD'96: Proceedings of the Second International Conference on Knowledge Discovery and Data Mining*, p. 226-231: AAAI Press. 1996-08-02. Dostupné na <https://dl.acm.org/doi/10.5555/3001460.3001507>
- [21] DBSCAN [online]. *Scikit-learn*. 2012-05-30. Dostupné na <https://scikit-learn.org/stable/modules/generated/sklearn.cluster.DBSCAN.html>
- [22] DBSCAN for Anomaly Detection [online]. *Kaggle*. 2023. Dostupné na <https://www.kaggle.com/code/luckypen/dbscan-for-anomaly-detection>
- [23] CHRISTOPHER M. BISHOP. B. SCHÖLKOPF, M. JORDAN, J. KLEINBERG (eds.). Pattern Recognition and Machine Learning. *Springer Science+Business Media, LLC, 233 Spring Street, New York, NY 10013, USA, 2006*. ISBN-10 0-387-31073-8. Dostupné na <https://www.microsoft.com/en-us/research/wp-content/uploads/2006/01/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf>
- [24] Anomaly detection (GMM) [online]. *EDGE IMPULSE*. 2025-09-10. Dostupné na <https://docs.edgeimpulse.com/studio/projects/learning-blocks/blocks/anomaly-detection-gmm>
- [25] DANIEL STANLEY TAN. Deep Autoencoding Gaussian Mixture Model for Unsupervised Anomaly Detection in PyTorch [online]. *GitHub*. 2018-04-13. Dostupné na <https://github.com/danielstan07/dagmm>
- [26] Decision Tree in Machine Learning [online]. *GeeksForGeeks*. 2025-12-23. Dostupné na <https://www.geeksforgeeks.org/machine-learning/decision-tree-introduction-example/>

- [27] What Is a Support Vector Machine [online]. *MathWorks*. 2014-08-21. Dostupné na <https://www.mathworks.com/discovery/support-vector-machine.html>
- [28] K-Nearest Neighbor(KNN) Algorithm [online]. *GeeksForGeeks*. 2025-12-23. Dostupné na <https://www.geeksforgeeks.org/machine-learning/k-nearest-neighbours/>
- [29] Random Forest Algorithm in Machine Learning [online]. *GeeksForGeeks*. 2025-12-23. Dostupné na <https://www.geeksforgeeks.org/machine-learning/random-forest-algorithm-in-machine-learning/>
- [30] KEERTHANAMS. Building Blocks of Deep Learning: ANN, CNN, RNN, and Transformers [online]. *Medium*. 2025-04-05. Dostupné na <https://medium.com/@keerthanams1208/building-blocks-of-deep-learning-ann-cnn-rnn-and-transformers-0e0f830d090f>
- [31] JAVIER PULIDO-CEJUDO. Diagram of supervised and unsupervised learning algorithms [online]. *ResearchGate*. Feb 2020. Dostupné na https://www.researchgate.net/figure/Diagram-of-supervised-and-unsupervised-learning-algorithms_fig4_339339675
- [32] Outlier detection with Local Outlier Factor (LOF) [online]. *Scikit-learn*. 2018-10-05. Dostupné na https://scikit-learn.org/stable/auto_examples/neighbors/plot_lof_outlier_detection.html
- [33] NISHA ARYA. K-Means Clustering for Unsupervised Machine Learning [online]. *Ejable*. 2023-11-10. Dostupné na <https://www.ejable.com/tech-corner/ai-machine-learning-and-deep-learning/k-means-clustering/>
- [34] JYM FROST. Principal Component Analysis Guide & Example [online]. *Statistics By Jim*. 2023-01-29. Dostupné na <https://statisticsbyjim.com/basics/principal-component-analysis/>
- [35] PREETHI THAKUR. DBSCAN Algorithm — Density Based Spatial Clustering of Application with Noise [online]. *Medium*. 2022-11-08. Dostupné na <https://medium.com/@preethithakur/dbscan-algorithm-density-based-spatial-clustering-of-application-with-noise-a826538dcb42>
- [36] Gaussian Mixture Model [online]. *GeeksForGeeks*. 2025-11-18. Dostupné na <https://www.geeksforgeeks.org/machine-learning/gaussian-mixture-model/>
- [37] AMY. One-Class SVM For Anomaly Detection [online]. *Medium*. 2022-03-25. Dostupné na <https://medium.com/grabngoinfo/one-class-svm-for-anomaly-detection-6c97fdd6d8af>

- [38] KHALED A. ALAGHBARI, HENG-SIONG LIM, MOHAMAD HANIF MD SAAD, YIK SENG YONG. Deep Autoencoder-Based Integrated Model for Anomaly Detection and Efficient Feature Extraction in IoT Networks. *MDPI, IoT* 2023, 4(3), 345-365. 2023-08-25. Dostupné na <https://www.mdpi.com/2624-831X/4/3/16>
- [39] KOHEI-MU. Industrial Machine Anomaly Detection [online]. *Kaggle*. 2020. Dostupné na <https://www.kaggle.com/code/koheimuramatsu/industrial-machine-anomaly-detection>
- [40] MINESH A. JETHVA. ECG Anomaly Detection [online]. *Kaggle*. 2020. Dostupné na <https://www.kaggle.com/code/mineshjethva/ecg-anomaly-detection>
- [41] PATRICK FLEITH. NASA Battery Dataset [online]. *Kaggle*. 2022. Dostupné na https://www.kaggle.com/datasets/patrickfleith/nasa-battery-dataset/data/code?select=cleaned_dataset
- [42] OKUNOLA OROGUN. Credit card transaction dataset (fraud detection) [online]. *Kaggle*. 2024. Dostupné na <https://www.kaggle.com/datasets/orogunadebola/credit-card-transaction-dataset-fraud-detection>
- [43] SALVATORE STOLFO, WEI FAN, WENKE LEE, ANDREAS PRODROMIDIS, PHILIP CHAN. KDD Cup 1999 Data [online]. *UC Irvine, Machine Learning Repository*. 1998-12-31. Dostupné na <https://archive.ics.uci.edu/dataset/130/kdd+cup+1999+data>
- [44] Statlog (Shuttle) [online]. *UC Irvine, Machine Learning Repository*. 2023-10-16. Dostupné na <https://archive.ics.uci.edu/dataset/148/statlog+shuttle>
- [45] H. GUVENIR, BURAK ACAR, HALDUN MUDERRISOGLU, R. QUINLAN. Arrhythmia [online]. *UC Irvine, Machine Learning Repository*. 1997-12-31. Dostupné na <https://archive.ics.uci.edu/dataset/5/arrhythmia>
- [46] JOCK BLACKARD. Coverttype [online]. *UC Irvine, Machine Learning Repository*. 1998-07-31. Dostupné na <https://archive.ics.uci.edu/dataset/31/coverttype>
- [47] SWaT [online]. *iTrust, Singapore University of Technology and Design, CSA Singapore*. 2019-09-20. Dostupné na <https://www.sutd.edu.sg/itrust/swat/>
- [48] PATRICK FLEITH. NASA Anomaly Detection Dataset SMAP & MSL [online]. *Kaggle*. 2022. Dostupné na <https://www.kaggle.com/datasets/patrickfleith/nasa-anomaly-detection-dataset-smap-msl>
- [49] AHMAD, S., LAVIN, A., PURDY, S., & AGHA, Z. Unsupervised real-time anomaly detection for streaming data [online]. *Neurocomputing*. 2017-06-02. ISSN 0925-2312. Dostupné na <https://doi.org/10.1016/j.neucom.2017.04.070>

- [50] SUSANKET SARKAR, MOHAN KISHORE (ed.). RUL Prediction using Variational Autoencoder LSTM [online]. *Kaggle*. 2024. Dostupné na <https://www.kaggle.com/code/susanketsarkar/rul-prediction-using-variational-autoencoder-lstm>
- [51] ADITYA KUMAR. NASA Battery Dataset Analysis [online]. *Kaggle*. 2025. Dostupné na <https://www.kaggle.com/code/ankulml/nasa-battery-dataset-analysis>
- [52] ALEXANDER LAVIN. Numenta Anomaly Benchmark (NAB) [online]. *Kaggle*. 2016. Dostupné na <https://www.kaggle.com/datasets/boltzmannbrain/nab>

Prílohy

Príloha A – Programové súbory

Táto príloha obsahuje prehľad hlavných programových súborov použitých pri implementácii a experimentálnom overení metód detekcie anomálií:

- **Autoencoder_NASA.ipynb** – Implementácia metódy Autoencoder pre dataset NASA Battery
- **Autoencoder_NAB.ipynb** – Implementácia metódy Autoencoder pre dataset NAB
- **Autoencoder_ECG5000.ipynb** – Implementácia metódy Autoencoder pre dataset ECG5000
- **Isolation_Forest_NASA.ipynb** – Implementácia metódy Isolation Forest pre dataset NASA Battery
- **Isolation_Forest_NAB.ipynb** – Implementácia metódy Isolation Forest pre dataset NAB
- **Isolation_Forest_ECG5000.ipynb** – Implementácia metódy Isolation Forest pre dataset ECG5000
- **OneClass_SVM_NASA.ipynb** – Implementácia metódy One-Class SVM pre dataset NASA Battery
- **OneClass_SVM_NAB.ipynb** – Implementácia metódy One-Class SVM pre dataset NAB
- **OneClass_SVM_ECG5000.ipynb** – Implementácia metódy One-Class SVM pre dataset ECG5000

- **nasa_battery.ipynb** – Predspracovanie datasetu NASA Battery
- **nab.ipynb** – Predspracovanie datasetu NAB

Poznámka: Dataset ECG5000 nevyžadoval samostatný súbor pre predspracovanie. Načítanie dát, vytvorenie binárnych anotácií anomálií a štandardizácia boli implementované priamo v notebookoch jednotlivých experimentov.

Príloha B – Používateľská príručka

Účel riešenia

Vyvinuté riešenie slúži na detekciu anomálií v dátach pomocou metód strojového učenia. Implementované boli tri metódy: Isolation Forest, One-Class SVM a Autoencoder. Experimenty boli realizované na datasetoch NAB, ECG5000 a NASA Battery.

Štruktúra projektu

Repozitár obsahuje zdrojové kódy pre jednotlivé experimenty a predspracovanie dát:

- **nab.ipynb** – predspracovanie datasetu NAB,
- **nasa_battery.ipynb** – predspracovanie datasetu NASA Battery,
- **Isolation_Forest_*.ipynb** – experimenty s metódou Isolation Forest,
- **OneClass_SVM_*.ipynb** – experimenty s metódou One-Class SVM,
- **Autoencoder_*.ipynb** – experimenty s metódou Autoencoder.

Postup použitia

- Dataset NAB
 1. Stiahnuť dataset NAB. [52]
 2. Umiestniť súbory do adresára definovaného v konfigurácii notebooku.
 3. Spustiť notebook *nab.ipynb*.
 4. Po vytvorení predspracovaných dát spustiť príslušný experimentálny notebook.
- Dataset NASA Battery
 1. Stiahnuť dataset NASA Battery. [41]
 2. Umiestniť súbory do adresára definovaného v konfigurácii notebooku.
 3. Spustiť notebook *nasa_battery.ipynb*.
 4. Notebook vytvorí predspracovaný dataset *nasa_battery_features_rolling.csv*.
 5. Následne spustiť požadovaný experimentálny notebook.
- Dataset ECG5000
 1. Umiestniť súbory *ECG5000_TRAIN.txt* a *ECG5000_TEST.txt* do príslušného adresára.

2. Spustiť vybraný experimentálny notebook.

Výstupy programu

Po vykonaní experimentov sú automaticky vytvorené:

- tabuľky s výslednými metrikami,
- konfúzne matice,
- histogramy skóre anomálií,
- histogramy rekonštrukčnej chyby (Autoencoder),
- súhrnné výsledky experimentov.

Hodnotenie modelov

Výsledky sú vyhodnocované pomocou metrík:

- Accuracy,
- Precision,
- Recall,
- F1-skóre.

Tieto metriky umožňujú porovnať úspešnosť jednotlivých metód pri detekcii anomálií.

Zdrojové kódy

Zdrojové kódy sú dostupné v repozitári GitHub:

<https://github.com/mikotonoku/BachelorThesis-Anomaly-Detection-SK>

Príloha C – Inštalácia a konfigurácia

Požiadavky na softvérové prostredie

Riešenie bolo implementované v programovacom jazyku Python a testované v prostredí Jupyter Notebook. Pre správnu funkčnosť je potrebné mať nainštalované:

- Python 3.10 alebo novší,
- Anaconda Distribution (odporúčané),
- Jupyter Notebook alebo JupyterLab.

Použité knižnice

Pri implementácii boli použité nasledujúce knižnice:

- pandas,
- numpy,
- scikit-learn,
- tensorflow,
- keras,
- matplotlib,

- seaborn,
- scipy.

Inštalácia knižníc

V prípade použitia prostredia Anaconda je možné požadované knižnice nainštalovať pomocou príkazu:

```
pip install pandas numpy scikit-learn tensorflow keras
matplotlib seaborn scipy
```

Získanie datasetov

Použité datasety nie sú súčasťou repozitára z dôvodu ich veľkosti a licenčných podmienok. Je potrebné ich stiahnuť z verejne dostupných zdrojov:

- NASA Battery Dataset [41]
- NAB (Numenta Anomaly Benchmark) [52]
- ECG5000 [40]

Konfigurácia projektu

Po stiahnutí datasetov je potrebné upraviť cesty k vstupným súborom v jednotlivých notebookoch podľa umiestnenia dát v lokálnom počítači.

Pred spustením experimentov je potrebné vykonať predspracovanie dát:

- pre dataset **NAB** spustením notebooku *nab.ipynb*,
- pre dataset **NASA Battery** spustením notebooku *nasa_battery.ipynb*.

Notebook *nasa_battery.ipynb* vytvorí súbor *nasa_battery_features_rolling.csv*, ktorý je následne využívaný všetkými experimentmi realizovanými na datasete NASA Battery.

Spustenie experimentov

Po úspešnom predspracovaní dát je možné spustiť jednotlivé experimentálne notebooky:

Isolation Forest

- Isolation_Forest_NAB.ipynb
- Isolation_Forest_ECG5000.ipynb
- Isolation_Forest_NASA.ipynb

One-Class SVM

- OneClass_SVM_NAB.ipynb
- OneClass_SVM_ECG5000.ipynb
- OneClass_SVM_NASA.ipynb

Autoencoder

- Autoencoder_NAB.ipynb
- Autoencoder_ECG5000.ipynb
- Autoencoder_NASA.ipynb

Po dokončení výpočtov sa automaticky vytvoria výsledné tabuľky, konfúzne matice a grafické výstupy použité pri vyhodnotení experimentov.

Použitie nástrojov umelej inteligencie

Pri vypracovaní bakalárskej práce bol použitý nástroj generatívnej umelej inteligencie ChatGPT 5.5 (OpenAI).

Nástroj bol využitý na:

- preklad textových častí práce z ruského a anglického jazyka do slovenského jazyka,
- jazykové úpravy a reformulácie textu s cieľom zlepšiť štylistickú a gramatickú úroveň práce,
- vysvetľovanie odbornej problematiky súvisiacej s detekciou anomálií, strojovým učením a použitými metódami,
- pomoc pri analýze datasetov a interpretácii ich charakteristík,
- pomoc pri sumarizácii a interpretácii výsledkov experimentov,
- analýzu vybraných odborných a študijných materiálov súvisiacich s témou práce,
- generovanie a úpravu častí programového kódu v jazyku Python, najmä pri automatizácii spracovania experimentálnych výsledkov, organizácii výstupných súborov a tvorbe grafických vizualizácií.

Nástroj umelej inteligencie nebol použitý na formulovanie pôvodných vedeckých záverov ani na samostatné vypracovanie riešenia práce. Všetky experimenty, implementácie, výsledky, interpretácie a záverečné hodnotenia boli navrhnuté, overené a spracované autorom práce.